UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

O Problema de Empacotamento de Peças Irregulares em *Bins*[1]

Diego Yoshihiro Hono

São Carlos – SP

O Problema de Empacotamento de Peças Irregulares em *Bins*[1]

Diego Yoshihiro Hono

Orientadora: **Dra. Petra Maria Bartmeyer**

Coorientadora: **Profa. Dra. Franklina M. B. Toledo**

Monografia final de conclusão de curso apresentada ao Instituto de Ciências Matemáticas e de Computação – ICMC-USP, como requisito parcial para obtenção do título de Bacharel em Matemática Aplicada e Computação Científica.
Área de Concentração: Otimização

USP – São Carlos
Novembro de 2021

[1] Agradecemos à FAPESP pelo apoio financeiro que possibilitou o desenvolvimento desta pesquisa (processos n. 2021/04602-1, 2020/15707 e 2018/07240-0).

RESUMO

HONO, D. Y.. **O Problema de Empacotamento de Peças Irregulares em *Bins***[1]. 2021. 58 f. Monografia (Graduação) – Instituto de Ciências Matemáticas e de Computação (ICMC/USP), São Carlos – SP.

O problema de empacotamento de itens irregulares é um problema NP-difícil, que tem por objetivo definir uma disposição das peças a serem cortadas num recipiente de forma que elas estejam totalmente contidas nele e não se sobreponham. No setor de confecções, para fins de qualidade do produto final, as peças que o compõem devem ser cortadas a partir de um mesmo lote de tecido. Por exemplo, as mangas, a frente e as costas de uma camiseta devem ser cortadas em conjunto. Em geral, o processo de corte é realizado dispondo o tecido em uma mesa, logo sua largura e seu comprimento são fixos, o que pode ser interpretado como um problema de empacotamento em *bins*. O objetivo deste trabalho é maximizar o número de produtos finais cortados em cada *bin*, minimizando, portanto, a perda de tecido. Um modelo de programação matemática foi desenvolvido para o problema estudado usando como ponto de partida um modelo da literatura. Devido à complexidade computacional do problema, são analisados os casos para os quais a abordagem apresenta bom desempenho e em quais casos ela falha. Além disso, foi realizado um estudo de técnicas de aprendizado de máquinas para aplicá-las ao problema estudado, procurando, assim, métodos para aumentar a robustez do modelo matemático proposto.

Palavras-chave: Modelagem matemática, Corte e Empacotamento, Peças irregulares, Aprendizado de máquina.

SUMÁRIO

1 INTRODUÇÃO 7
1.1 Objetivos e Contribuições 8
1.2 Organização da monografia 8
1.3 Financiamento 8

2 DEFINIÇÃO E MODELAGEM DO PROBLEMA 9
2.1 Conceitos geométricos 10
2.2 Modelo de Toledo *et al.* (2013) 11
2.3 Modelo Desenvolvido 13
2.4 Considerações 14

3 GERAÇÃO DE MALHAS 15
3.1 *2-eixos* 16
3.2 *1-eixo* 17
3.3 *Recipiente dividido* 17

4 APRENDIZADO DE MÁQUINA PARA GERAÇÃO DE MALHAS . 19

5 EXPERIMENTOS COMPUTACIONAIS 22
5.1 Instâncias teste 22
5.2 Análise da abordagem desenvolvida 23
5.3 Análise das malhas geradas 23
5.3.1 Treinamento dos parâmetros *24*
5.3.2 Análise dos resultados obtidos *26*

6 CONCLUSÕES E PESQUISAS FUTURAS 30

REFERÊNCIAS 32

APÊNDICES 33

Capítulo 1

INTRODUÇÃO

O problema de empacotamento de itens irregulares é um problema NP-difícil (FOWLER; PATERSON; TANIMOTO, 1981), onde deseja-se encontrar uma disposição dos itens num recipiente de tal forma que eles estejam inteiramente contidos no recipiente e não se sobreponham. Seu objetivo mais frequente é encontrar um empacotamento de modo que o comprimento do objeto necessário seja o menor possível. Esse problema tem aplicações em diferentes indústrias, como a têxtil e de confecção (AMARO-JUNIOR; PINHEIRO; SARAIVA, 2013), a calçadista (HEISTERMANN; LENGAUER, 1995), e a metalúrgica (PLANKOVSKYY *et al.*, 2020). A literatura sobre o problema é extensa (LEÃO *et al.*, 2020; BENNELL; OLIVEIRA, 2009; SATO *et al.*, 2019; ALVAREZ-VALDES; CARRAVILLA; OLIVEIRA, 2018) e muitas são suas variações (WÄSCHER; HAUBNER; SCHUMANN, 2007).

Este trabalho é inspirado no setor de confecções, em que o tecido é disposto em mesas para depois ser realizado o corte. Portanto, o comprimento e a largura do tecido são fixos formando um retângulo (objeto ou *bin*) onde as peças devem ser posicionadas para o corte. Este problema é conhecido como problema de empacotamento de peças em *bins* e como destacado por Martinez-Sykora *et al.* (2017) ainda foi pouco estudado na literatura. Outro ponto relevante do problema é que em confecções os produtos finais são compostos por diferentes itens. Por exemplo, supondo o corte de uma camiseta, temos que cortar suas mangas, sua frente e suas costas. Note que cada camisa (peça final) é formada por um subconjunto de itens (frente, costas, mangas, colarinho, etc.). Na Figura 1, uma solução para um problema de corte de camisas é ilustrada.

Figura 1 – Exemplo de solução para o corte de camisas.

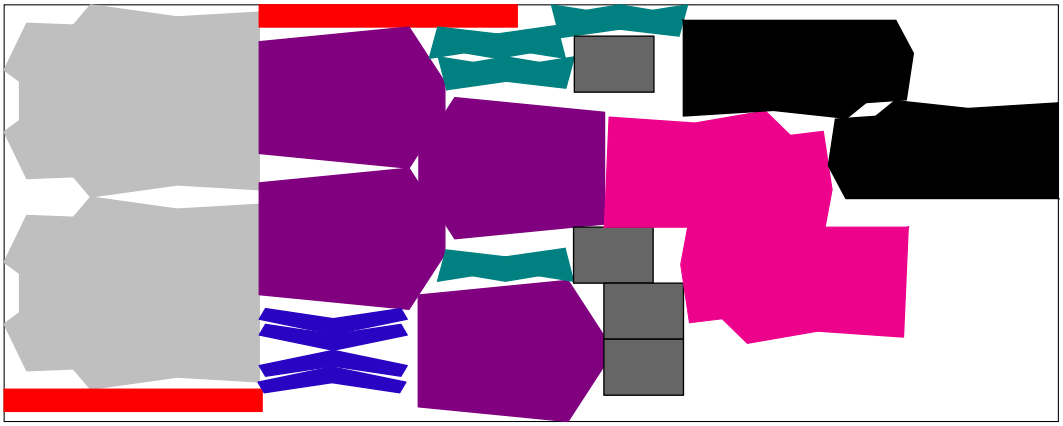

Fonte: Elaborada pelo autor

É importante destacar que os itens de um mesmo produto final devem ser cortados em um mesmo *bin*. Esta questão é relevante, em especial, por dois motivos: a) permitir que ao término do corte do *bin*, o processo de produção dos produtos finais possa ser iniciado; e b) assegurar a padronização dos produtos finais, evitando possíveis diferenças de tons do tecido entre itens de um mesmo produto. Dentre suas particularidades, destaca-se que as rotações dos itens não são permitidas uma vez que a orientação do tecido é importante para a confecção do produto final.

1.1 Objetivos e Contribuições

Este trabalho tem por objetivo central tratar o problema de empacotamento em *bin* considerando a necessidade de cortar os itens de um mesmo produto final em um mesmo *bin*. Neste sentido, são apresentadas duas contribuições para a área.

A primeira contribuição do trabalho é a proposta de um novo modelo matemático para representar o problema. Este modelo é baseado em (TOLEDO *et al.*, 2013) e, portanto, utiliza uma malha de pontos para representar o objeto.

Como destacam Toledo *et al.* (2013) e Cherri *et al.* (2018), o número de pontos da malha influência diretamente na qualidade da solução a ser obtida e no tempo computacional necessário para obtê-la, portanto, a segunda contribuição deste trabalho é investigar o uso de aprendizado de máquina (*machine learning*) para obter malhas mais adequadas para diferentes instâncias do problema. Além disso, também é estudada a possibilidade de reaproveitar essas malhas para outras instâncias com as mesmas peças.

1.2 Organização da monografia

O trabalho está organizado da seguinte maneira. No Capítulo 2, é definido o problema estudado e seu contexto na literatura. Os conceitos de geração de malhas são apresentados no Capítulo 3. No Capítulo 4, os conceitos de aprendizado por reforço e como eles foram utilizados para a escolha de malhas são resumidos. Experimentos computacionais para avaliar os métodos desenvolvidos são reportados no Capítulo 5. Por fim, no Capítulo 6, são apresentadas algumas considerações finais e propostas para trabalhos futuros.

1.3 Financiamento

Essa pesquisa recebeu financiamento dos projetos FAPESP 2021/04602-1 , FAPESP 2020/15707-6 e FAPESP 2018/07240-0.

Capítulo 2

DEFINIÇÃO E MODELAGEM DO PROBLEMA

Como destacado no Capítulo 1, o problema estudado é inspirado no setor de cortes de confecções. Em confecções, os produtos finais são compostos por diferentes itens (peças), que devem ser cortados e depois encaminhados para o setor de costura e acabamento. Por exemplo, o corte de um shorts é composto de duas partes da frente e duas das costas, além do cós e dos bolsos, dependendo do modelo.

No processo de corte, primeiramente, o tecido é disposto em uma mesa de corte formando um retângulo (objeto ou *bin*). Na segunda etapa, as peças dos produtos finais são posicionadas no objeto formando um plano de corte, que em seguida é cortado. O objetivo central é que o plano de corte escolhido minimize os retalhos gerados, ou seja, maximize a área útil utilizada no corte dos produtos finais. Minimizar as perdas é relevante por pelo menos duas razões: o melhor aproveitamento do tecido contribui para a minimização dos custos de produção; enquanto, os retalhos não descartados diminuem a geração de lixo.

Como descrito anteriormente, no contexto de confecções, os itens de um mesmo produto final devem ser cortados a partir de um mesmo *bins* e numa mesma etapa, em especial por dois motivos: i) permitir que ao término do corte do *bin*, o processo de produção dos produtos finais possa ser iniciado; e ii) assegurar a padronização dos produtos finais, evitando possíveis diferenças de tons do tecido entre itens de um mesmo produto cortados a partir de *bins* distintos.

Além de impor que as peças que compõem um dado produto final sejam cortadas a partir de um mesmo *bin*, também é necessário que as peças estejam completamente contidas no objeto e que não haja sobreposição entre elas, pois caso contrário seriam gerados produtos finais defeituosos. A Figura 2a ilustra um exemplo de um item parcialmente fora do objeto, enquanto a Figura 2b ilustra a ocorrência de sobreposição. Dentre outras particularidades do problema, destaca-se que as rotações dos itens não são permitidas uma vez que a orientação do tecido é importante para a confecção do produto final.

Observe que esse problema pode ser visto como um problema de empacotamento de peças irregulares bidimensionais em *bins*. Assim, os aspectos geométricos envolvidos na verificação da factibilidade acarretam desafios computacionais, mais especificamente, a verificação da existência de sobreposição entre itens e se os itens estão completamente contidos no objeto. A literatura apresenta algumas formas de abordar a verificação de factibilidade (BENNELL; OLIVEIRA, 2008). Neste trabalho, é proposto um modelo matemático para representar o

Figura 2 – Restrições do problema.

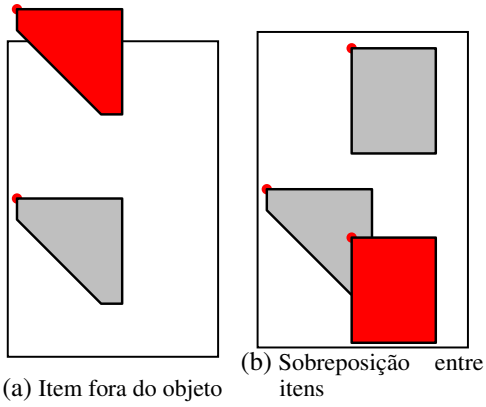

Fonte: Elaborada pelo autor.

problema baseado em (TOLEDO *et al.*, 2013), que tratam as questões geométricas utilizando os conceitos de *no-fit polygon* e *inner-fit polygon*. A principal vantagem dessa abordagem geométrica é a possibilidade de definir as posições relativas entre dois tipos de itens em uma etapa de pré-processamento. Dada sua relevância, estes conceitos são descritos na Seção 2.1. Em seguida, na Seção 2.2, o modelo matemático desenvolvido é detalhado.

2.1 Conceitos geométricos

Problemas com peças irregulares têm um desafio adicional resultante do tratamento da geometria das peças. Neste trabalho, são utilizados os conceitos de *no-fit polygon* e *inner-fit polygon* para tratar a não sobreposição entre peças e garantir que elas estejam totalmente alocadas no objeto, respectivamente. Antes, no entanto, é destacado que a representação de uma peça é dada por um polígono com um ponto de referência para seu posicionamento. Essa forma de representação é necessária para utilizar os conceitos de *no-fit polygon* e *inner-fit polygon*.

***No-fit polygon*:** Dadas as peças i e j, o *no-fit polygon* de i e j (denotado por NFP_{ij}) é definido como o espaço tal que se i está fixado e o ponto de referência de j for posicionado em $p \in NFP_{ij}^{\circ}$, então i e j se sobrepõem; e se o ponto de referência de j for posicionado em $p \in \partial NFP_{ij}$, então as peças se tocam. Na Figura 3a, é ilustrado um exemplo do *no-fit polygon* entre duas peças.

***Inner-fit polygon*:** Dado um objeto e uma peça i, o *inner-fit polygon* de i (denotado por IFP_i) é definido como o espaço dentro do objeto tal que se o ponto de referência da peça i for posicionado em $p \in IFP_i$, então a peça estará totalmente contida no objeto. Na Figura 3b, é ilustrado o *inner-fit polygon* para uma peça.

Utilizando os conceitos geométricos aqui descritos, na próxima sessão, é apresentado o modelo matemático desenvolvido para representar o problema de empacotamento de itens irregulares bidimensional em *bins*.

Figura 3 – Exemplo Ilustrativo.

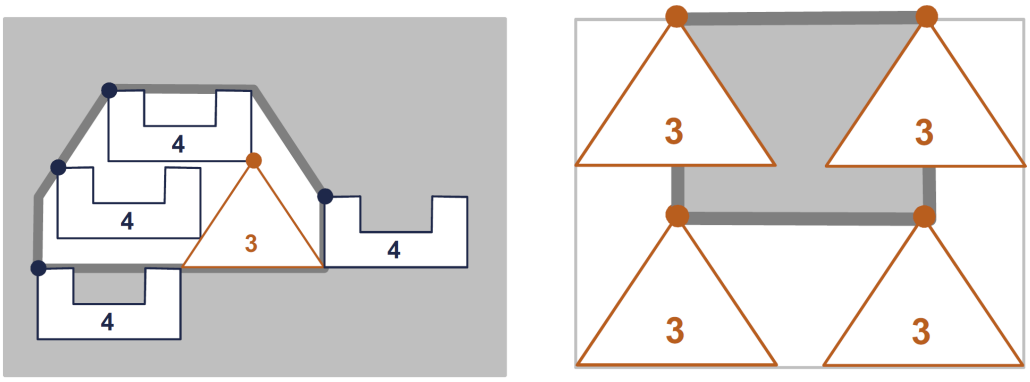

(a) *No-fit polygon* entre 3 e 4 (b) *Inner-fit polygon* da peça 3

Fonte: Toledo *et al.* (2013).

2.2 Modelo de Toledo *et al.* (2013)

O modelo matemático de Toledo *et al.* (2013) foi utilizado como base para o desenvolvimento de um modelo para tratar o problema de empacotamento de itens irregulares bidimensional em *bins*. Diferentemente do problema aqui estudado, em (TOLEDO *et al.*, 2013), o objetivo é minimizar o comprimento de um recipiente retangular (com altura fixa) de forma que seja possível posicionar todos os itens demandados. Os autores desenvolveram um modelo de empacotamento baseado na discretização do recipiente por meio de uma malha regular, isto é, por meio de pontos representados por uma grade quadriculada. Nesse tipo de abordagem, é atribuído um ponto de referência para cada item e cada ponto da malha é uma possível posição para posicionar os itens. Na Figura 4, é ilustrada uma solução proveniente dessa modelagem, onde cada ponto vermelho corresponde ao ponto de referência de um item, seu número representa seu tipo, as linhas tracejadas representam a malha e a linha vermelha indica o comprimento mínimo utilizado para empacotar todos os itens demandados.

Figura 4 – Exemplo de empacotamento para uma instâncias com três itens.

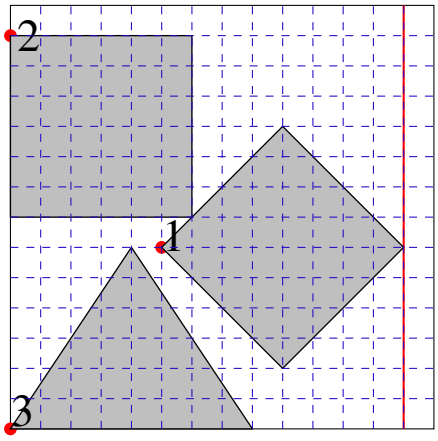

Fonte: Elaborado pelo autor.

Numa etapa de pré-processamento, o conjunto de pontos da malha factíveis para o

empacotamento de cada tipo de item é reduzido utilizando o conceito de *inner-fit polygon*, enquanto a sobreposição dos itens é analisada com o uso de *no-fit polygon* (BENNELL; DOWSLAND; DOWSLAND, 2001). A seguir é descrito o modelo de Toledo *et al.* (2013) utilizado como base para esta pesquisa.

Conjuntos:

- $\mathscr{I}$ é o conjunto de tipos de itens, onde $i \in \mathscr{I}$ é o item do tipo i no conjunto;
- $\mathscr{B}$ é o conjunto de todos os pontos da malha;
- $\mathscr{B}_i$ é o subconjunto de pontos de $\mathscr{B}$ para os quais a alocação do item do tipo i é factível, ou seja, o item fica inteiramente contido no objeto. Em (TOLEDO *et al.*, 2013), $\mathscr{B}_i$ foi definido como o conjunto de pontos de $\mathscr{B}$ que pertencem ao *inner-fit polygon* da peça do tipo i;
- NFP_{ij}^k é o subconjunto de pontos de $\mathscr{B}$ que compõe o *no-fit polygon* entre as peças de tipo i e j caso a peça i seja alocada no ponto k.

Parâmetros:

- d_i é a demanda do item do tipo i;
- c_i é a diferença do diâmetro de Feret horizontal (ŽUNIĆ, 2018) e a coordenada x do ponto de referência do item i;
- x_k é a coordenada x do ponto k.

Variáveis:

- δ_{ik} é igual a 1 se um item do tipo i é alocado no ponto k, zero caso contrário;
- z é o comprimento total utilizado.

$$\min \quad z \tag{2.1}$$

$$\text{s.t.} \quad \sum_{k \in \mathscr{B}_i} \delta_{ik} = d_i, \quad \forall\, i \in \mathscr{I} \tag{2.2}$$

$$\delta_{jt} + \delta_{ik} \leq 1, \quad \forall t \in NFP_{ij}^k;\ \forall i, j \in \mathscr{I},\ i \neq j;\ \forall k \in \mathscr{B}_i \tag{2.3}$$

$$\delta_{jt} + \delta_{ik} \leq 1, \quad \forall t \in NFP_{ij}^k,\ t \neq k;\ \forall i, j \in \mathscr{I},\ i = j;\ \forall k \in \mathscr{B}_i \tag{2.4}$$

$$(x_k + c_i)\ \delta_{ik} \leq z, \quad \forall\, i \in \mathscr{I},\ k \in \mathscr{B}_i \tag{2.5}$$

$$z \geq 0 \tag{2.6}$$

$$\delta_{ij} \in \{0, 1\}, \quad \forall\, i \in \mathscr{I},\ j \in \mathscr{B}_i. \tag{2.7}$$

O modelo busca uma solução em que todas as peças sejam empacotadas no menor comprimento possível do objeto (2.1), ou seja, minimizando o comprimento do objeto definido pela variável z. As restrições (2.2) estabelecem que a demanda de cada item do tipo i seja atendida. A factibilidade do empacotamento dos itens no objeto é representada pelo conjunto de restrições (2.3) e (2.4), onde dois itens não podem se sobrepor e devem ser alocados de forma a estarem completamente no objeto ($k \in \mathscr{B}_i$). O comprimento utilizado do objeto é definido pela relação entre os pontos de alocação dos itens e a variável z. Esta relação é estabelecida pelo conjunto de restrições (2.5). O domínio das variáveis é definido em (2.6) e (2.7).

2.3 Modelo Desenvolvido

Para o problema a ser tratado nessa pesquisa, o objetivo é maximizar a área utilizada do *bin* considerando o número total de produtos finais cortados. Portanto, o modelo descrito anteriormente precisa ser adaptado para tratar esta questão. Assim, para impor que as peças de um produto final sejam cortadas em conjunto, é utilizado o seguinte conjunto de restrições:

$$d_w^{\min} \leq \Delta_w \leq d_w^{\max}, \quad \forall\, w \in W \tag{2.8}$$

$$\sum_{w \in W} n_{wi}\, \Delta_w = \sum_{k \in B_i} \delta_{ik}, \quad \forall\, i \in \mathscr{I} \tag{2.9}$$

em que:

- W é o conjunto de tipos de produtos finais a serem confeccionadas;
- $\Delta_w \in \mathbb{N}$ é uma variável inteira que corresponde ao número de produtos finais do tipo w confeccionados;
- $d_w^{\min}$ e $d_w^{\max}$ são os limitantes inferiores e superiores para a demanda de cada tipo de produto final w;
- n_{wi} é o número de itens do tipo i necessários para confeccionar um produto final do tipo w.

O conjunto de restrições (2.8) limita a demanda de produtos finais de cada tipo. As restrições (2.9) estabelecem a relação entre o número de peças individuais e produtos finais.

A nova função objetivo é dada por:

$$\max \sum_{w \in W} p_w \Delta_w \tag{2.10}$$

sendo p_w a ponderação para cada tipo de peça final a ser cortado, essa ponderação pode ter como base, por exemplo, a área total ocupada pela peça final (como é aqui utilizado) ou o preço de cada tipo de peça final.

Como o comprimento e a largura do objeto são fixos, a variável z e o conjunto de restrições (2.2) e (2.5) do modelo de Toledo *et al.* (2013) não são necessários. O modelo desenvolvido para tratar o problema é dado por (2.11)–(2.17). Para facilitar referências futuras ao modelo desenvolvido, sua função objetivo e restrições foram renumeradas. É importante destacar que as restrições (2.12), (2.13) e (2.17) foram originalmente apresentadas em (TOLEDO *et al.*, 2013); além disso, vale ressaltar que o conjunto de restrições (2.14) é facultativo no modelo, sendo usado caso o problema exija impor demandas.

$$\max \quad \sum_{w \in W} p_w \Delta_w \tag{2.11}$$

s.a

$$\delta_{jt} + \delta_{ik} \leq 1, \qquad \forall t \in \mathscr{N}\mathscr{F}\mathscr{P}^k_{ij};\ \forall i, j \in \mathscr{I},\ i \neq j;\ \forall k \in \mathscr{B}_i \tag{2.12}$$

$$\delta_{jt} + \delta_{ik} \leq 1, \qquad \forall t \in \mathscr{N}\mathscr{F}\mathscr{P}^k_{ij},\ t \neq k;\ \forall i, j \in \mathscr{I},\ i = j;\ \forall k \in \mathscr{B}_i \tag{2.13}$$

$$d_w^{\min} \leq \Delta_w \leq d_w^{\max}, \qquad \forall\, w \in W \tag{2.14}$$

$$\sum_{w \in W} n_{wi}\, \Delta_w = \sum_{k \in B_i} \delta_{ik}, \qquad \forall i \in \mathscr{I} \tag{2.15}$$

$$\Delta_w \in \mathbb{N}, \qquad \forall w \in W \tag{2.16}$$

$$\delta_{ij} \in \{0, 1\}, \qquad \forall\, i \in \mathscr{I},\ j \in \mathscr{B}_i. \tag{2.17}$$

2.4 Considerações

O problema de otimização linear inteira apresentado em (2.11)-(2.17) contém as mesmas características que fazem os demais problema de corte de peças irregulares NP-difíceis. Para tentar melhorar o processo de resolução do problema, pode-se utilizar diferentes tipos de malhas, ou seja, diferentes conjuntos $\mathscr{B}_i$, pois, em malhas regulares, como as utilizadas em Toledo *et al.* (2013) é frequente a ocorrência de soluções simétricas (soluções com o mesmo custo), o que aumenta o custo computacional para resolver o problema. Além disso, Cherri *et al.* (2018) afirmam que usar malhas regulares nem sempre é vantajoso, uma vez que:

i. podem ser gerados muitos pontos desnecessários, o que aumenta o custo computacional; e

ii. algumas peças podem ter poucas posições adequadas, o que prejudica o encaixe das peças e, consequentemente, a qualidade da solução.

Assim, Cherri *et al.* (2018) propuseram gerar as malhas $\mathscr{B}_i$ com base nas características dos tipos de peça, em vez de apenas filtrar os pontos da malha regular utilizando o *inner-fit polygon*. Os resultados mostraram que, para certas instâncias, usar malhas alternativas foi mais vantajoso, apresentando soluções de melhor qualidade e também exigindo menos tempo para resolução. Logo, neste trabalho, foi explorada uma forma alternativa para gerar malhas com base em aprendizado de máquina (*machine learning*) que é descrita no próximo capítulo.

Capítulo 3

GERAÇÃO DE MALHAS

Baseado no trabalho de Cherri *et al.* (2018), também foram geradas malhas que são específicas para cada tipo de item. É proposto gerar cada $\mathscr{B}_i$ utilizando a distribuição Beta (KEEPING, 1995), pois desta forma é possível controlar a densidade de pontos de cada $\mathscr{B}_i$ no recipiente e também esperar que isso reduza o número de soluções simétricas para o problema, ou seja, soluções com mesmo valor de função objetivo. Essa distribuição foi escolhida porque sua função de densidade de probabilidade possui uma grande variedade de formas ao variar seus parâmetros, como ilustra a Figura 5.

Figura 5 – Função de densidade de probabilidade da distribuição Beta.

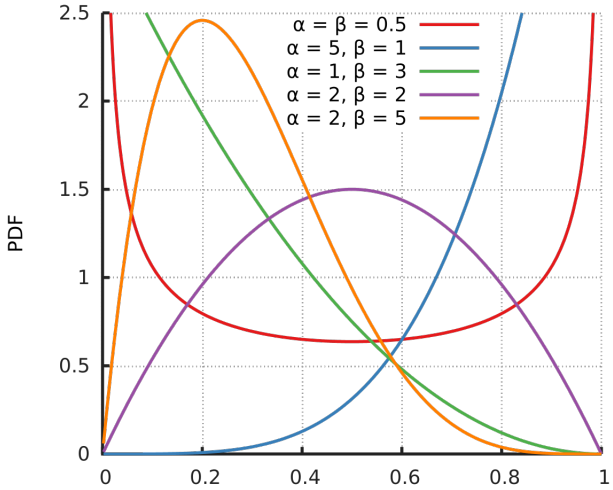

Fonte: Wikipédia. Acesso: 27/09/2021.

Desta forma, os conjuntos $\mathscr{B}_i$ podem ser gerados escolhendo os parâmetros que os pontos fiquem posicionados em regiões favoráveis para cada item i. Para isso, a cada eixo do objeto (x e y) é associada uma distribuição Beta(α,β) para gerar as coordenadas dos pontos.

Foram implementadas três versões dessa discretização: a primeira (denotada por *2-eixos*) dá a possibilidade de escolher os parâmetros de cada distribuição associada a cada eixo; a segunda versão (denotada por *1-eixo*) fixa as distribuições Beta associadas ao eixo y e varia os valores da distribuição Beta para o eixo x; a terceira versão (denotada por *Recipiente dividido*) divide o recipiente ao meio verticalmente e aplica *1-eixo* em cada parte. A seguir, cada um desses algoritmos é detalhado.

3.1 *2-eixos*

Como os recipientes tratados no problema são sempre retangulares, o *inner-fit polygon* de cada peça é um retângulo também. Faça c^i e C^i definirem os limites inferior e superior do comprimento do *inner-fit polygon* do item de tipo i e l^i e L^i os limites da altura. A distribuição Beta possui suporte igual ao intervalo $[0,1]$, então, denotando os conjuntos gerados pelo método *2-eixos* por $\mathscr{B}_i^{(2E)}$, pode-se definir os pontos desses conjuntos como sendo $(\bar{x},\bar{y})$ de forma que $\bar{x} = c^i + (C^i - c^i)x$ e $\bar{y} = l^i + (L^i - l^i)y$, onde x e y possuem distribuição Beta. Note que $(\bar{x},\bar{y})$ sempre estará dentro do *inner-fit polygon* do item de tipo i. Portanto, define-se os conjuntos $\mathscr{B}_i^{(2E)}$ da seguinte forma:

$$\begin{aligned}\mathscr{B}_i^{(2E)} =&\{(\bar{x}_m^i,\bar{y}_m^i);\ x_m^i \sim \text{Beta}(\alpha_x^i,\beta_x^i),\ y_m^i \sim \text{Beta}(\alpha_y^i,\beta_y^i),\\ &\bar{x}_m^i = c^i + (C^i - c^i)x_m^i,\ \bar{y}_m^i = l^i + (L^i - l^i)y_m^i,\ m = 1,\ldots,\ n_i\},\end{aligned}$$

onde α_x^i e β_x^i são parâmetros da distribuição Beta do item do tipo i associado ao eixo x e α_y^i e β_y^i são os parâmetros associados ao eixo y; n_i é a quantidade de pontos na malha do item i.

A Figura 6 ilustra um exemplo de conjuntos $\mathscr{B}_i^{(2E)}$ gerados para os itens de uma instância da literatura com três itens (*three*) e sua respectiva solução. Os pontos pretos se referem aos pontos em que o item 1 pode ser posicionado, ou seja, sua malha de pontos. Analogamente, os pontos vermelhos e verdes definem as malhas para os itens 2 e 3, respectivamente. Ao gerar pontos somente na região factível para cada item, permite-se o adensamento de pontos em regiões de interesse sem aumentar o número total de pontos das malhas.

Figura 6 – Solução da instância three - Modelo de Toledo *et al.* (2013).

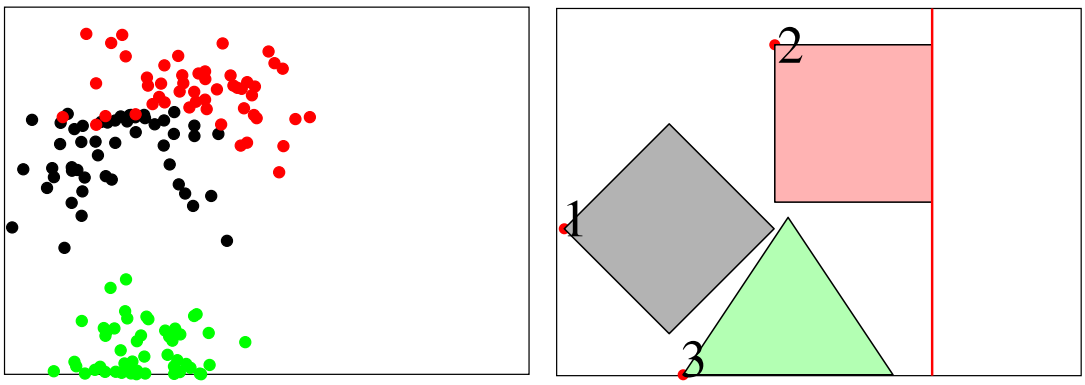

(a) Malha - *2-eixos* (b) Solução

Fonte: Elaborada pelo autor.

Desta forma, pode-se gerar cada $\mathscr{B}_i$ de acordo com as necessidades do item de tipo i. Esse método, no entanto, possui duas características importantes: i) o número de parâmetros a ser determinado é grande dependendo da instância, isso ocorre porque cada tipo de item requer quatro parâmetros para a geração da malha; e ii) esse método não consegue gerar múltiplas áreas de concentração de pontos para um mesmo tipo de item (pois a função de densidade de probabilidade

da distribuição Beta não possui formas para representar esse comportamento). Assim, também são propostos os métodos *1-eixo* e *Recipiente dividido* para tratar esses problemas.

3.2 *1-eixo*

A qualidade da solução do problema está diretamente relacionado aos pontos da malha. Logo, é preciso encontrar os parâmetros adequados para cada tipo de instância. Entretanto, isso não é uma tarefa trivial, pois, supondo que a instância a ser resolvida tenha n tipos de itens, será necessário determinar $4n$ parâmetros no total considerando a estratégia *2-eixos*. Sendo assim, é proposto o algoritmo *1-eixo*, que necessitará de menos parâmetros.

A ideia é fixar os parâmetros das distribuições beta associadas ao eixo y. Para isso, são utilizados os valores $\alpha_y^i = 1.0$ e $\beta_y^i = 1.0$ para todo $i \in I$, pois Beta(1.0,1.0) é equivalente à distribuição Uniforme(0.0,1.0) e, portanto, os valores das coordenadas do eixo y não serão tendenciosos para alguma peça i.

Então, os conjuntos $\mathscr{B}_i^{(1E)}$ são dados por:

$$\begin{aligned}\mathscr{B}_i^{(1E)} =& \{(\bar{x}_m^i, \bar{y}_m^i);\ x_m^i \sim \text{Beta}(\alpha_x^i, \beta_x^i),\ y_m^i \sim \text{Beta}(1.0, 1.0),\\ & \bar{x}_m^i = c^i + (C^i - c^i)x_m^i,\ \bar{y}_m^i = l^i + (L^i - l^i)y_m^i,\ m = 1, \ldots, n_i\},\end{aligned}$$

Note que, considerando uma instância com n tipos de itens, esse método precisa de $2n$ parâmetros. A Figura 7 apresenta um exemplo de conjuntos $\mathscr{B}_i^{(1E)}$ gerados para os itens da instância *three* e sua respectiva solução.

Figura 7 – Solução da instância three - Modelo de Toledo *et al.* (2013)

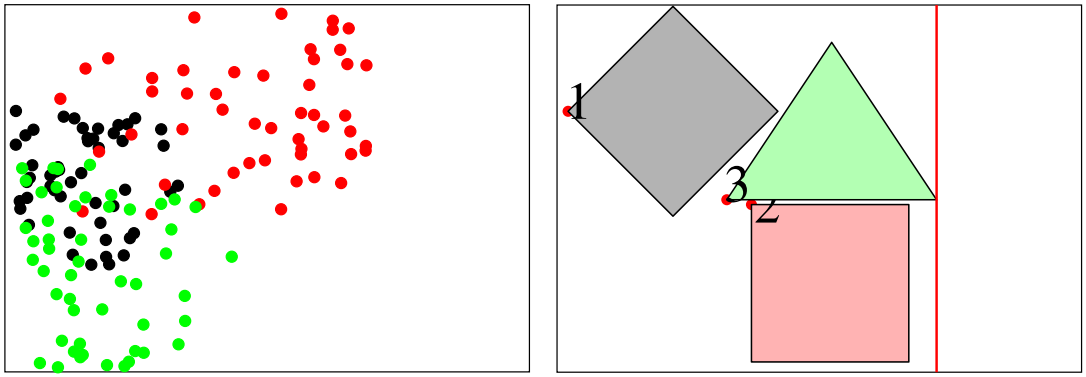

(a) Malha - *1-eixo* (b) Solução

.

Fonte: Elaborada pelo autor.

3.3 *Recipiente dividido*

Como citado anteriormente, quando é considerada diretamente a distribuição Beta, não é possível gerar múltiplas áreas de concentração de pontos. Portanto, o método *Recipiente*

dividido foi proposto. Este método separa o objeto em duas partes com um corte vertical e aplica a estratégia *1-eixo* em cada uma das partes. Com isso, espera-se gerar malhas com áreas de concentração de pontos mais dispersas.

Seja $\mathscr{B}_i^{(1)}$ o conjunto de pontos relacionado à primeira parte do objeto e $\mathscr{B}_i^{(2)}$ o conjunto relacionado à segunda, divide-se o número de pontos o mais igualmente entre eles, ou seja, $n_i^{(1)} = \lfloor \frac{n_i}{2} \rfloor$ e $n_i^{(2)} = n_i$, em que n_i é o número de pontos da malha para a peça i e $n_i^{(k)}$ é o número de pontos de cada parte do recipiente. Além disso, α_x^{i1} e β_x^{i1} são os parâmetros associados à $\mathscr{B}_i^{(1)}$, enquanto α_x^{i2} e β_x^{i2} são os parâmetros associados à $\mathscr{B}_i^{(2)}$.

Portanto, pode-se construir os conjuntos $\mathscr{B}_i^{(RD)}$ como:

$$\begin{aligned}
\mathscr{B}_i^{(1)} =& \{(\bar{x}_m^i, \bar{y}_m^i);\ x_m^i \sim \text{Beta}(\alpha_x^{i1}, \beta_x^{i1}),\ y_m^i \sim \text{Beta}(1.0, 1.0), \\
& \bar{x}_m^i = c^i + 0.5(C^i - c^i)x_m^i,\ \bar{y}_m^i = l^i + (L^i - l^i)y_m^i,\ m = 1, \ldots,\ n_i^{(1)}\}, \\
\mathscr{B}_i^{(2)} =& \{(\bar{x}_m^i, \bar{y}_m^i);\ x_m^i \sim \text{Beta}(\alpha_x^{i2}, \beta_x^{i2}),\ y_m^i \sim \text{Beta}(1.0, 1.0), \\
& \bar{x}_m^i = 0.5(C^i + c^i) + 0.5(C^i - c^i)x_m^i,\ \bar{y}_m^i = l^i + (L^i - l^i)y_m^i,\ m = n_i^{(1)} + 1, \ldots,\ n_i^2\},
\end{aligned}$$

$$\mathscr{B}_i^{(RD)} = \mathscr{B}_i^{(1)} \cup \mathscr{B}_i^{(2)}$$

Na Figura 8, é ilustrado um exemplo de conjuntos $\mathscr{B}_i^{(RD)}$ gerados para os itens da instância *three* e sua respectiva solução.

Figura 8 – Solução da instância three - Modelo de Toledo *et al.* (2013)

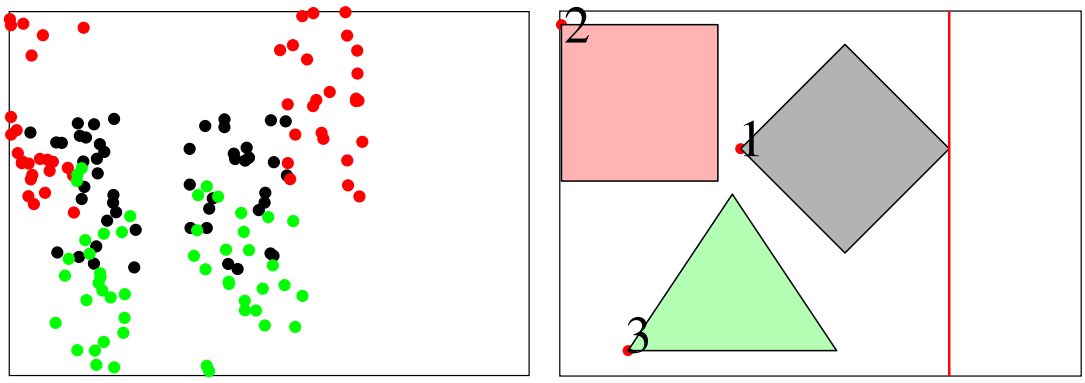

(a) Malha - *Recipiente dividido* (b) Solução

.

Fonte: Elaborada pelo autor.

Entretanto, se por um lado o uso da distribuição Beta permite diminuir o número de soluções simétricas e permite uma personalização da distribuição dos pontos no objeto para cada tipo de item, uma dificuldade desta metodologia é encontrar parâmetros ótimos para a distruição. Em todos os métodos (*1-eixo, 2-eixos* e *Recipiente dividido*), é preciso calcular esses parâmetros para obter uma boa solução, portanto, é proposto utilizar técnicas de aprendizado de máquina combinadas com programação inteira mista para encontrar parâmetros ótimos. No próximo capítulo, são apresentados detalhes de como esta técnica foi utilizada no contexto deste trabalho.

Capítulo 4

APRENDIZADO DE MÁQUINA PARA GERAÇÃO DE MALHAS

Métodos de aprendizado de máquina vêm se mostrando promissores para auxiliar técnicas de otimização, em especial para na solução de problemas combinatórios (BENGIO; LODI; PROUVOST, 2021). Eles têm sido aplicados diretamente ao método de solução, como para a verificação de factibilidade (GAHM *et al.*, 2021), ou ainda em etapas de pré-processamento, como para a seleção de métodos de solução a serem utilizados (RAKOTONIRAINY, 2020).

Neste trabalho, a técnica de aprendizado por reforço *Q-learning* (SUTTON; BARTO, 2018) é utilizada para a definição dos parâmetros da distribuição Beta usados para gerar malhas. O algoritmo *Q-learning* utiliza uma matriz de aprendizado que sumariza cada umas das decisões possíveis em cada estágio da solução do problema. Uma função de avaliação é utilizada para recompensar ou punir cada ação a depender do impacto dela para a qualidade da solução alcançada. A seguir, será explicada a implementação do *Q-learning* para o método *2-eixos*; a forma para aplicar a técnica nos demais métodos é análogo.

Os possíveis valores dos parâmetros α_x^i, β_x^i, α_y^i e β_y^i foram discretizados para evitar a busca em espaço contínuo. Para isso, um intervalo para os parâmetros é fixado e os conjuntos A_p, que discretiza o intervalo dos parâmetros α, e B_p que discretiza o intervalos dos parâmetros β são criados. O conjunto das possíveis combinações de parâmetros P é dado por $P = \{(\alpha, \beta);\ \alpha \in A_p,\ \beta \in B_p\}$.

O uso de representação discreta permite o mapeamento do espaço de busca dos parâmetros em uma matriz $Q \in \mathbb{R}^{i \times j \times p}$, onde $p \in \{1, \ldots, |P|\}$ indica o p-ésimo elemento de P, $j \in \{x, y\}$ indica o eixo associado à distribuição e $i \in \mathscr{I}$ indica o tipo do item. Dessa forma, para cada item i e eixo j, tem-se uma combinação p para os parâmetros.

No algoritmo de aprendizado proposto, o método *Q-learning* utiliza a matriz Q para computar as recompensas/penalizações relacionadas a cada combinação de parâmetros. A Figura 9 resume os passos do método de treinamento proposto para a escolha dos parâmetros da distribuição Beta.

A matriz Q é uma matriz multi-dimensional que acomoda cada uma das combinações possíveis entre os parâmetros a serem utilizados. Inicialmente, ela é uma matriz nula. A cada iteração do método *Q-learning* uma combinação dos parâmetros é escolhida e uma malha

Figura 9 – Fluxograma do esquema de treinamento proposto.

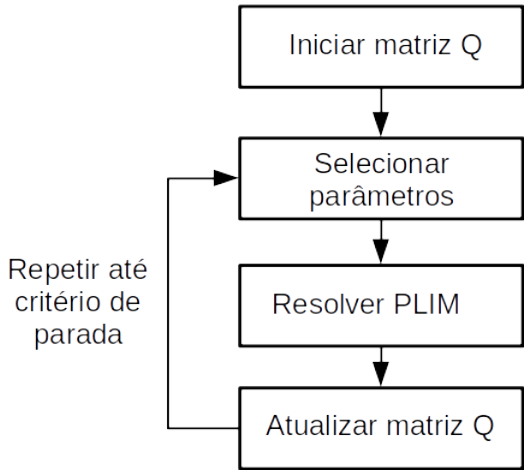

Fonte: Elaborada pelo autor.

aleatória é gerada considerando as características da distribuição Beta para os valores escolhidos. Uma vez que a malha é definida, uma problema de programação linear inteiro misto (PLIM) é resolvido, no caso deste trabalho, o modelo (2.11)-(2.17). O valor da função objetico do PLIM é utilizada para avaliar a qualidade da malha gerada, e assim atualizar os valores da matriz Q. Esse processo é repetido até que um critério de parada seja atingido. A descrição detalhada de como esse esquema de aprendizado foi aplicado nesse trabalho é apresentado no Algoritmo 1, onde os parâmetros λ, $MaxIte$ e n_i, $\forall i \in \mathscr{T}$, são a taxa de decaimento, o número máximo de iterações e o número de pontos na malha do item i, respectivamente.

Note que a avaliação de uma escolha de parâmetros requer a resolução de um PLIM, o que pode ser bastante custoso. Então, permite-se que a solução final à cada iteração tenha até $5,0\%$ de GAP relativo. O critério de parada foi definido como um número máximo de iterações. As malhas propostas foram personalizadas para cada instância, ou seja, a escolha de parâmetros é dependente da instância.

No Algoritmo 1, o uso da roleta ponderada permite dar maior probabilidade para os parâmetros com melhores resultados durante o processo de busca, acelerando a convergência do método.

Note que o número de parâmetros a serem escolhidos para os métodos *2-eixos* e *Recipiente dividido* é o dobro do número de parâmetros de *1-eixo*, e como é considerado a combinação entre esses parâmetros, o espaço de busca de *1-eixo* é significativamente menor que dos outros métodos. Portanto, é esperado que *1-eixo* convirja antes. Porém, precisa-se estudar se a qualidade e o custo computacional das soluções não é prejudicada por essa falta de liberdade de escolha. A forma de aplicar o *Q-learning* para os métodos *1-eixo* e *Recipiente dividido* é mostrado pelos Algoritmos 3 e 4 respectivamente, que se encontram no Apêndice 6.

Algoritmo 1: *Q-learning* para geração de malhas aleatórias - Método *2-eixos*

1 **Parâmetros:** P, $\lambda > 0$, $MaxIter$, n_i e os demais parâmetros do modelo;
2 Inicializar $Q \leftarrow 0$; ; Inicializar $prob \leftarrow 1$; % Probabilidade de explorar;
3 Inicializar $MelhorCusto \leftarrow 0$;
4 Inicializar $prob \leftarrow 1$; % Probabilidade de explorar;
5 **while** $k \leq MaxIter$ **do**
6 $\quad r \leftarrow rand(0,1)$;
7 $\quad$ **if** $r \leq prob$ **then**
8 $\quad\quad$ São escolhidos aleatoriamente p^*_{ij}, $\forall i,\ j$;
9 $\quad$ **else**
10 $\quad\quad$ p^*_{ij} são escolhidos utilizando uma **Roleta ponderada parcial** (Algoritmo 2);
11 $\quad$ Gerar a malha M com os parâmetros escolhidos;
12 $\quad$ $CustoAtual \leftarrow$ Custo do problema resolvido com M;
13 $\quad$ **if** $CustoAtual \geq MelhorCusto$ **then**
14 $\quad\quad$ $MelhorCusto \leftarrow CustoAtual$;
15 $\quad\quad$ $Q_{ijp^*_{ij}} \leftarrow Q_{ijp^*_{ij}} + 1$, $\forall i,\ j$
16 $\quad$ $k \leftarrow k+1$;
17 $\quad$ $prob \leftarrow e^{-\lambda * k}$
18 retorna Q

Algoritmo 2: Roleta ponderada parcial

1 Dados Q, i e j;
2 $minQp \leftarrow min(Q_{ij})$;
3 $vetAux \leftarrow Q_{ij} - minQp + 0.01$ % Operação para deixar todos os elementos de $Q_{ij} \geq 0$.;
4 $p^* \leftarrow$ Aplica roleta ponderada para os 10 elementos cujo valor em *vetAux* são os maiores;
5 Retorna p^*

Capítulo 5

EXPERIMENTOS COMPUTACIONAIS

Neste capítulo, são descritos os experimentos computacionais realizados para avaliar as abordagens desenvolvidas. O modelo desenvolvido foi implementado em linguagem de modelagem utilizando a linguagem Julia e a biblioteca JuMP e as instâncias foram resolvidas utilizando o solver Gurobi (v9.12). O ambiente computacional era equipado com um processador Intel Xeon E5-2620 (2.00 GHz x 24), memória RAM de 64 GB e o sistema operacional Ubuntu 12.04, limitando a 4 *threads*.

5.1 Instâncias teste

As instâncias teste utilizadas foram inspiradas nas instâncias disponíveis em (ESICUP, 2021) e são descritas na Tabela 1. A coluna "Instância" identifica a instância, e as colunas "L" e "C" definem, respectivamente, a largura e o comprimento do objeto utilizado. Para cada instância foi criado um conjunto de peças que forma um produto final, que estão descritos na coluna "Conjuntos". No caso das instâncias $marques_2$, o número entre parenteses indica a demanda da peça antecedente para o produto final. Em todas as instâncias, não foi definido um limite mínimo d_w^{min} ou máximo d_w^{max} para a demanda dos produtos finais.

Tabela 1 – Dados das instâncias utilizadas.

Instância	L	C	Conjuntos
rco_1	15	25	$\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}, \{7\}$
rco_2	15	25	$\{1,3\}, \{4,5,7\}, \{2,6\}$
rco_3	15	25	$\{1,5\}, \{2,7\}, \{3,4,6\}$
rco_4	15	25	$\{1,6,7\}, \{2,4\}, \{3,5\}$
rco_5	15	25	$\{1,2,7\}, \{3,6\}, \{4,5\}$
$blazewicz_1$	15	25	$\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}, \{7\}$
$blazewicz_2$	15	25	$\{1,3\}, \{4,5,7\}, \{2,6\}$
$blazewicz_3$	15	25	$\{1,5\}, \{2,7\}, \{3,4,6\}$
$blazewicz_4$	15	25	$\{1,6,7\}, \{2,4\}, \{3,5\}$
$blazewicz_5$	15	25	$\{1,2,7\}, \{3,6\}, \{4,5\}$
$marques_1$	104	86	$\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}, \{7\}, \{8\}$
$marques_2$	104	86	$\{1(2),3,7,8\}, \{2\}, \{4\}, \{5\}, \{6\}$

Vale ressaltar que os itens da instância *rco* são envoltórias convexas dos itens da instância *blazewicz*. Já os itens da instância *marques* representam peças de uma camiseta somadas a outro conjunto de peças livres.

Note que a primeira instância para cada conjunto de peças não possui produtos finais que usam diversos itens, enquanto as demais exploram a possibilidade de diferentes conjuntos de

peças para cada produto final. Estas instâncias foram criadas para avaliar o problema de corte de produtos finais.

5.2 Análise da abordagem desenvolvida

Neste primeiro experimento computacional, as instâncias descritas na Tabela 1 foram representadas pelo modelo matemático (2.11)-(2.17) utilizando uma malha regular com discretização unitária para as instâncias *rco* e *blazewicz* e discretização $3,5$ unidades para as instâncias *marques* (devido ao tamanho do objeto). O objetivo é analisar a relevância de considerar o corte de peças de um mesmo produto final em um mesmo *bin*. Para tanto, as instâncias teste foram abordadas utilizando a modelagem desenvolvida.

Na Tabela 2, a coluna "Instância" identifica a instância resolvida, "NV" é o número de variáveis do modelo, "Área (%)" é a porcentagem de ocupação do *bin* (ou seja, é razão entre o valor da função objetivo do modelo e a área do recipiente), "T (s)" é o tempo de resolução da instância em segundos (não foi considerado o tempo gasto para gerá-la) e "GAP (%)" é o desvio relativo da melhor solução obtida para seu limitante dual. Na última coluna, é reportada a quantidade de cada produto final cortado e entre parenteses a quantidade que teria sido cortada a partir do resultado da instância rco_1 para as instâncias rco_k, analogamente a quantidade de produtos finais cortados para $blazewicz_k$ e $marques_2$.

Tabela 2 – Soluções obtidas utilizando a abordagem desenvolvida (malha regular).

Instância	NV	Área (%)	T (s)	GAP (%)	Produtos Finais
rco_1	1850	96,8	93	0	0, 0, 0, 15, 3, 0, 3
rco_2	1846	91,0	587	0,0	1(0), 7(3), 1(0)
rco_3	1846	90,4	1800	0,9	2(0), 7(0), 3(0)
rco_4	1846	90,0	1800	0,4	0(0), 9(0), 0(0)
rco_5	1846	87,6	1801	3,4	5(0), 5(0), 1(0)
$blazewicz_1$	1850	94,9	197	0,0	0, 0, 0, 0, 4, 5, 66
$blazewicz_2$	1846	84,5	1800	4,8	4(0), 4(0), 3(0)
$blazewicz_3$	1846	83,4	1800	6,1	3(0), 6(0), 3(0)
$blazewicz_4$	1846	83,4	1800	9,2	4(0), 6(0), 1(0)
$blazewicz_5$	1846	84,5	1800	5,8	3(0), 6(0), 3(0)
$marques_1$	3650	85,9	852	0,0	12, 0, 2, 0, 1, 2, 0, 0
$marques_2$	3647	78,0	1800	7,5	2(0), 1(0), 1(0), 8(1), 3(2)

Pelos resultados obtidos, nota-se a necessidade de trabalhar com o conceito de produtos finais, pois os resultados da Tabela 2 mostram que tratar apenas peças individuais embora resulte numa melhor ocupação do objeto, não leva a soluções com muitos produtos finais formados, o que atrasaria a confecção dos produtos finais

5.3 Análise das malhas geradas

Inicialmente, é realizado o treinamento dos parâmetros para geração das malhas. Para

tanto, primeiramente, o desempenho em tempo computacional e qualidade de solução é avaliado com relação ao número de pontos gerados para cada malha, denominada aqui granularidade da malha. Em seguida, os métodos de geração de malhas são avaliados. Finalmente, uma vez definida os parâmetros das distribuições Beta que gerarão as malhas, as instâncias foram representadas pelo modelo (2.11)-(2.17) e que foi resolvido pelo *solver* GUROBI tendo como tempo limite 1800 segundos. Os resultados são comparados com a malha regular.

5.3.1 Treinamento dos parâmetros

Para o treinamento dos parâmetros das malhas aleatórias, foram utilizadas as instâncias rco_1, $blazewicz_1$ e $marques_1$, uma vez que elas não possuem conjuntos para formar peças finais e, portanto, espera-se que o treinamento gere malhas adequadas para cada tipo de peça.

Dadas as características do modelo (2.11)-(2.17), o número de variáveis binárias do problema cresce proporcionalmente ao número de pontos da malha. O *tradeoff* é que malhas com mais pontos possibilitam melhor representação do espaço de busca e tendem a resultar em soluções melhores, por outro lado, elas demandam maior custo computacional. Para definir a relação entre o número de pontos da malha, a perda em qualidade de solução e o ganho em custo computacional, foram realizados testes considerando malhas aleatórias com três granularidades: 33%, 66% e 100% da quantidade de pontos utilizados por uma malha regular. Ou seja, são geradas malhas aleatórias considerando $|\mathscr{B}_i^A| = \mathscr{A}(p * |B_i|)$, onde a função $\mathscr{A} : \mathbb{R} \to \mathbb{N}$ é a função de arredondamento e $p \in \{0,33;\ 0,66;\ 1,0\}$ é a porcentagem dos pontos.

Gráficos compilando os resultados obtidos para a instância rco_1 são ilustrados na Figura 10a. Vale ressaltar que, como as malhas geradas são aleatórias, para cada porcentagem de pontos, foram geradas 5 malhas utilizando os mesmos parâmetros. A porcentagem média de ocupação e o tempo médio de execução são apresentados. No gráfico da esquerda, é reportada para cada porcentagem de pontos a média da área máxima ocupada. Por exemplo, para uma malha com 66% dos pontos de uma malha regular, tem-se uma área ocupada média de pouco mais de 74%. O gráfico da direita resume os tempos médios necessários para resolver a instância a partir de cada malha gerada. Os resultados obtidos para a instância $blazewicz_1$ mostram o mesmo comportamento da rco_1, e são ilustrados na Figura 10b. Com relação a instância $marques_1$, os resultados são ligeiramente diferentes, como ilustra a Figura 10c.

Como pode-se observar nas Figuras 10a-10c, a porcentagem 66% apresenta o melhor *tradeoff* entre qualidade da solução e tempo computacional necessário para as instâncias rco_1 e $blazewicz_1$, enquanto 33% é melhor para $marques_1$, pois para as duas primeiras instâncias, o ganho de qualidade ao utilizar 100% não é muito alto ao comparar com o aumento no tempo. Já para a instância $marques_1$, usar mais que 33% implica em tempo computacional muito elevado. Vale lembrar que para aplicar o *Q-learning*, é necessário resolver o modelo a cada iteração, o que é bastante custoso mesmo permitindo um GAP de até 5,0% da solução ótima.

Figura 10 – *Tradeoff* entre granularidade e porcentagem de ocupação, e granularidade e tempo de solução.

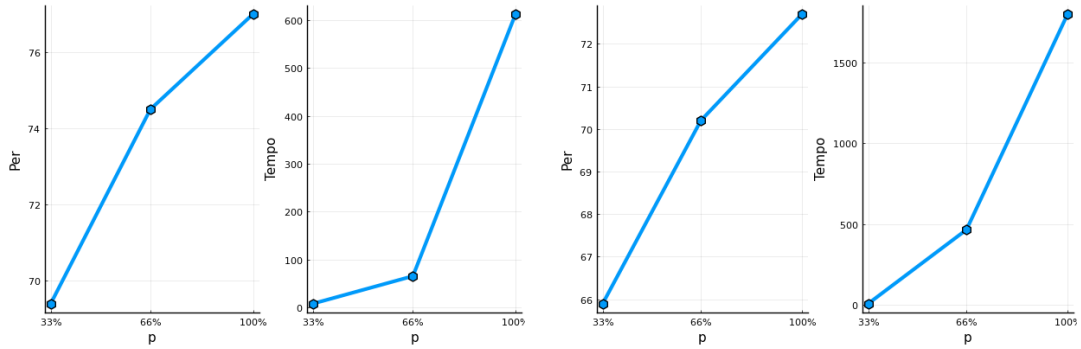

(a) Instância rco_1.

(b) Instância $blazewicz_1$.

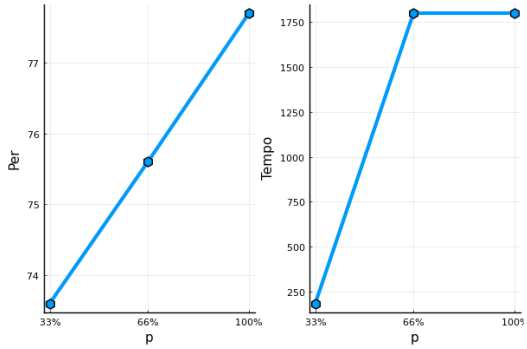

(c) Instância $marques_1$.

Uma vez determinado o número de pontos da grade, deve-se definir os parâmetros da distribuição Beta, cuja discretização estudada é dada por $P_1 = \{(\alpha, \beta);\ \alpha \in \{0,5;\ 1,0;\ ...,\ 4,5;\ 5,0\}, \beta \in \{0,5;\ 1,0;\ ...;\ 4,5;\ 5,0\}\}$ para as instâncias com malhas do tipo *2-eixos* e *Recipiente dividido*. Para a malha do tipo *1-eixo*, foi usado $P_2 = \{(\alpha, \beta);\ \alpha \in \{0,5;\ 1,0;\ ...,\ 6,5;\ 7,0\},\ \beta \in \{0,5;\ 1,0;\ ...;\ 6,5;\ 7.0\}\}$, pois o número de parâmetros para esse método é menor, então foi possível analisar um intervalo mais amplo. Os demais parâmetros são reportados na Tabela 3.

Tabela 3 – Parâmetros para o método *Q-learning*.

Instâncias	λ	*MaxIter*	p
rco_1			66%
$blazewicz_1$	0,0005	2600	66%
$marques_1$			33%

Para visualizar a evolução do *Q-learning*, foram elaborados gráficos para as três instâncias escolhidas. Na Figura 11, é apresentada a evolução para a instância rco_1 em que o eixo x descreve a iteração em que houve melhora da função objetivo, enquanto no eixo y é apontado o valor da melhora relativa , ou seja, quanto o valor da função objetivo melhorou em relação à solução antiga. É possível notar que as malhas geradas pelo método *1-eixo* melhoram continuamente, tendo apenas dois picos (no início e entre 500 e 1000 iterações). Porém, tanto o método *2-eixo* como *Recipiente dividido* têm mais picos. Pode-se atribuir esse comportamento à diferença no número de parâmetros dos métodos. Como foi apresentado no Capítulo 3, o método *1-eixo*

utiliza metade dos parâmetros necessários para os outros métodos, sendo assim, é esperado que ele convirja antes. Este comportamento é semelhante para as instâncias $blazewicz_1$ e $marques_1$, cujos gráficos estão disponíveis no Apêndice 19.

Figura 11 – Instância rco_1 - Evolução do *Q-learning*

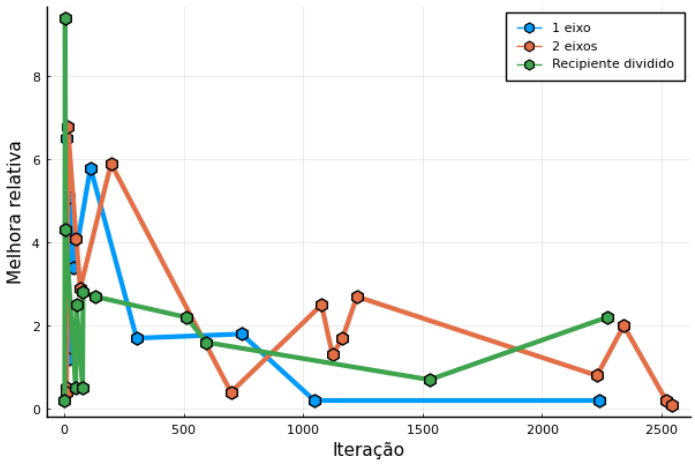

5.3.2 Análise dos resultados obtidos

Os testes computacionais apresentados a seguir analisam dois fatores, o primeiro é a vantangem do treinamento dos parâmetros da função Beta, para isso os resultados são comparados com uma malha gerada uniformemente. O segundo fator analisado é a influência da granularidade da malha para a qualidade da solução e o tempo de solução. Assim, para cada tipo de malha foram gerados 33%, 66% e 100% do número de pontos da malha regular. As instâncias teste foram resolvidas utilizando quatro tipos de malhas: *Sem treinamento*, que são malhas geradas com parâmetros iguais a 1,0, e malhas treinadas para cada método (*1-eixo*, *2-eixos* e *Recipiente dividido*). Todos os resultados obtidos são reportados nas tabelas disponíveis no Apêndice B.

Com base nos resultados obtidos, podê-se observar que entre os métodos de geração de malha, o *2-eixos* apresenta melhores resultados, pois a qualidade das suas soluções é ligeiramente melhor que das soluções dos outros métodos na maioria dos casos. Já o tempo de resolução significativamente menor na maior parte das instâncias. Em relação aos desvios padrões, os que se referem à porcentagem de ocupação não são significativos, entretanto, os desvios padrões nos tempo são bem mais expressivos, mostrando novamente que o método *2-eixos* possui vantagem sobre os outros por ser mais estável (apresentar desvios menores) quando se trata das instâncias *rco* e *blazewicz* para as porcentagens 33% e 66%, e *marques* na porcentagem 33%. Nos demais casos, ou os resultados se tornam bem mais instáveis, ou o desvio padrão se torna muito pequeno porque o tempo limite é atingido em todos as iterações. Sendo assim, iremos comparar os resultados da malha *2-eixos* com a malha sem treinamento e a malha regular.

Na Tabela 4, é apresentada uma comparação dos resultados obtidos usando a malha obtida sem treinamento e a malha treinada obtida pelo método *2-eixos* utilizando 66% dos pontos. As colunas “D-Área” e “D-T” indicam a diferença da porcentagem da área ocupada e do tempo de

resolução entre as abordagens, respectivamente. A coluna ”SD-Área” indica a diferença do desvio padrão de área ocupada em relação às malhas e ”SD-T” reflete a diferença do desvio padrão no tempo de execução. Valores negativos (em vermelho) mostram melhor desempenho da malha sem treinamento, enquanto valores positivos (em azul) indicam vantagem da abordagem *2-eixos*. Observa-se em todos os casos uma grande redução no tempo computacional da malha *2-eixos* exceto para instância $marques_2$, em que ocorre um empate técnico. Em relação à qualidade de solução e estabilidade, novamente a malha *2-eixos* se mostra superior. A comparação para outras porcentagens está no Apêndice B. Vale lembrar que o treinamento foi feito usando a primeira instância de cada conjunto de peças, portanto pode-se concluir que é vantajoso reaproveitar as malhas treinadas nesse caso.

Tabela 4 – Comparação dos resultados malha *2-eixos* x malha *Sem treinamento* (66% dos pontos).

Instância	D-Área (%)	SD-Área (%)	D-T (s)	SD-T (s)
rco_1	1.0	0.5	29	11
rco_2	0.1	-0.5	357	170
rco_3	1.0	-0.6	379	133
rco_4	0.4	0.3	445	264
rco_5	1.0	1.6	870	814
$blazewicz_1$	0.8	-0.0	435	382
$blazewicz_2$	-0.3	-0.1	597	208
$blazewicz_3$	0.4	-0.1	1056	493
$blazewicz_4$	1.7	2.6	1477	243
$blazewicz_5$	1.3	-0.1	1327	507
$marques_1$	2.5	0.5	1077	-601
$marques_2$	1.8	0.1	>-1	>-1

Os resultados mais competitivos foram obtidos pela malha com 66% dos pontos e se encontram na Tabela 21. Aqui, os números em vermelho significam perda em relação à malha regular, enquanto os números em azul representam ganho. Observa-se que a qualidade da malha regular é superior em todos os casos quando se refere a ocupação da placa, sendo essa diferença maior para as instâncias do tipo *rco* e *blazewicz*. Contudo, quando se analisa o tempo de solução nota-se uma forte vantagem da estratégia usando malhas aleatórias. Com relação aos tempos computacionais, conclui-se que o ganho é significativo para as instâncias *rco* e *blazewicz* com porcentagem 33% e 66%; para o caso de 100%, esses grandes ganhos vieram com grande desvio padrão. Já para as instâncias do tipo *marques*, a vantagem de tempo se mostrou relevante apenas no caso de porcentagem 33% pelos mesmos motivos.

A vantagem na qualidade da solução ocorre provavelmente porque os itens dessas instâncias são bastante favorecidos pela malha regular (Figuras 12a e 12b), uma vez que possuem largura e comprimento inteiros e, portanto, fazem um bom aproveitamento da malha 1 por 1. Entretanto, para as instâncias do tipo *marques*, a discretização de uma unidade não é viável devido à sua grande dimensão. Além disso, é possível ver que o encaixe das peças dessa instância é mais difícil (Figura 13). Por esses motivos, note que o desempenho da malha *2-eixos* não foi

Tabela 5 – Comparação dos resultados malha *2-eixos* x malha regular (66% dos pontos).

Instância	D-Área (%)	SD-Área (%)	D-T (s)	SD-T (s)
rco_1	-21,3	1,1	56	14
rco_2	-20,4	1,3	546	9
rco_3	-18,3	1,4	1682	140
rco_4	-18,4	0,8	1738	30
rco_5	-16,6	0,5	1757	9
$blazewicz_1$	-23,9	0,9	167	7
$blazewicz_2$	-16,7	0,5	1664	27
$blazewicz_3$	-15,1	1,1	1648	75
$blazewicz_4$	-15,1	0,5	1622	81
$blazewicz_5$	-15,8	0,9	1676	25
$marques_1$	-7,8	0,7	129	601
$marques_2$	-3,3	1,1	<1	<1

tão inferior nesse caso. As comparções entre as malhas regulares e o método *2-eixos* para 33%, 66% e 100% dos pontos estão disponíveis no Apêndice B.

Figura 12 – Itens instâncias *rco* e *blazewicz* e suas respectivas malhas regulares.

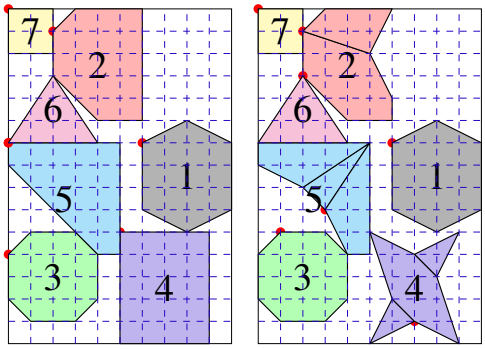

(a) Instância *rco* (b) Instância *blazewicz*

Figura 13 – Itens instância *marques* e sua respectiva malha regular.

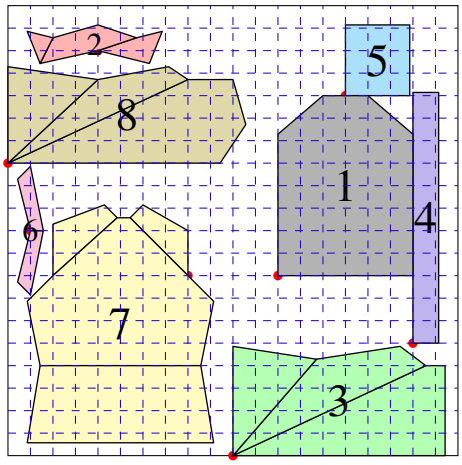

Capítulo 6

CONCLUSÕES E PESQUISAS FUTURAS

Neste trabalho, foi estudado o problema de empacotamento de peças irregulares em *bin* considerando a necessidade de cortar os itens de um mesmo produto final em um mesmo *bin*. Por causa da natureza do problema, é possível tratá-lo como problema de empacotamento de peças irregulares bidimensionais em *bins*.

Duas são as contribuições deste trabalho. Primeiramente, um modelo matemático foi desenvolvido para representar o problema. Este modelo é baseado em (TOLEDO *et al.*, 2013) e, portanto, utiliza uma malha de pontos para representar o objeto. Como destacam Toledo *et al.* (2013) e Cherri *et al.* (2018), o número de pontos da malha influência diretamente na qualidade da solução a ser obtida e no tempo computacional necessário para obtê-la, portanto, a segunda contribuição deste trabalho é investigar o uso de *machine learning* para obter malhas mais adequadas para diferentes instâncias do problema. Além disso, também foi avaliada a possibilidade de reaproveitar essas malhas para outras instâncias com as mesmas peças.

Os resultados computacionais mostraram a relevância de tratar o problema de corte de produtos finais, uma vez que se o corte for planejado visando a melhor utilização do tecido, considerando apenas os itens demandados poucos produtos finais podem ser produzidos de imediato, levando a uma espera do setor responsável pelo acabamento dos produtos.

Para gerar novas malhas, foram desenvolvidos 3 métodos: *1-eixo*, *2-eixos* e *Recipiente dividido*. Com os resultados obtidos, concluímos que o método *2-eixos* é o melhor entre eles para as instâncias utilizadas. Os tempos computacionais obtidos pelo método são muito inferiores aos reportados para malhas regulares. Entretanto, a qualidade das soluções ainda é inferior que das soluções utilizando malhas regulares. Destaca-se que dentre as instâncias utilizadas são favorecidas pela discretização da malha 1 por 1, pois a altura e comprimento das peças são dados por valores inteiros. Neste sentido, a malha regular acaba por ser favorecida. As malhas *2-eixos* trazem resultados competitivos com um menor número de pontos nas malhas, logo, estudar a geração das malhas utilizando *machine learning* é promissor, pois malhas com menos pontos permitem obter resultados mais rapidamente.

Os resultados permitem concluir que deve-se explorar em pesquisas futuras outras formas de utilizar técnicas de aprendizado de máquina para gerar malhas. Uma ideia seria utilizar um método de ranqueamento para selecionar os pontos mais promissores da malha regular. Dessa forma, se bem sucedido, seria possível reduzir significativamente o número de variáveis binárias, o que permitiria utilizar malhas regulares em instâncias maiores ou até mesmo utilizar uma malha regular bastante refinada. Também deveriam ser avaliadas mais instâncias considerando as malhas propostas para identificar em que contexto elas seriam mais apropriadas.

REFERÊNCIAS

ALVAREZ-VALDES, R.; CARRAVILLA, M. A.; OLIVEIRA, J. F. Cutting and packing. In: ____. **Handbook of Heuristics**. [S.l.]: Springer International Publishing, 2018. p. 1–46. Citado na página 7.

AMARO-JUNIOR, B.; PINHEIRO, P. R.; SARAIVA, R. D. A hybrid methodology for nesting irregular shapes: Case study on a textile industry*. **IFAC Proceedings Volumes**, v. 46, n. 24, p. 15–20, 2013. 6th IFAC Conference on Management and Control of Production and Logistics. Citado na página 7.

BENGIO, Y.; LODI, A.; PROUVOST, A. Machine learning for combinatorial optimization: A methodological tour d'horizon. **European Journal of Operational Research**, v. 290, n. 2, p. 405–421, 2021. Citado na página 19.

BENNELL, J. A.; DOWSLAND, K. A.; DOWSLAND, W. B. The irregular cutting-stock problem—a new procedure for deriving the no-fit polygon. **Computers & Operations Research**, Elsevier, v. 28, n. 3, p. 271–287, 2001. Citado na página 12.

BENNELL, J. A.; OLIVEIRA, J. F. The geometry of nesting problems: A tutorial. **European journal of operational research**, Elsevier, v. 184, n. 2, p. 397–415, 2008. Citado na página 9.

____. A tutorial in irregular shape packing problems. **Journal of the Operational Research Society**, v. 60, p. S93–S105, 2009. Citado na página 7.

CHERRI, L. H.; CHERRI, A. C.; CARRAVILLA, M. A.; OLIVEIRA, J. F.; TOLEDO, F. M. B.; VIANNA, A. C. G. An innovative data structure to handle the geometry of nesting problems. **International Journal of Production Research**, Taylor & Francis, v. 56, n. 23, p. 7085–7102, 2018. Citado 4 vezes nas páginas 8, 14, 15 e 30.

ESICUP. **Working Group on Cutting and Packing within EURO**. 2021. Disponível em: <www.euro-online.org/websites/esicup/data-sets/#1535972088237-bbcb74e3-b507.Acesso: 18/11/2021.> Citado na página 22.

FOWLER, R. J.; PATERSON, M. S.; TANIMOTO, S. L. Optimal packing and covering in the plane are np-complete. **Information processing letters**, Elsevier, v. 12, n. 3, p. 133–137, 1981. Citado na página 7.

GAHM, C.; UZUNOGLU, A.; WAHL, S.; GANSCHINIETZ, C.; TUMA, A. Applying machine learning for the anticipation of complex nesting solutions in hierarchical production planning. [available online]. **European Journal of Operational Research**, Elsevier, 2021. Citado na página 19.

HEISTERMANN, J.; LENGAUER, T. The nesting problem in the leather manufacturing industry. **Annals of Operations Research**, Springer, v. 57, n. 1, p. 147–173, 1995. Citado na página 7.

KEEPING, E. S. **Introduction to statistical inference**. [S.l.]: Courier Corporation, 1995. Citado na página 15.

LEÃO, A. A.; TOLEDO, F. M.; OLIVEIRA, J. F.; CARRAVILLA, M. A.; ALVAREZ-VALDÉS, R. Irregular packing problems: a review of mathematical models. **European Journal of Operational Research**, Elsevier, v. 282, n. 3, p. 803–822, 2020. Citado na página 7.

MARTINEZ-SYKORA, A.; ALVAREZ-VALDES, R.; BENNELL, J.; RUIZ, R.; TAMARIT, J. Matheuristics for the irregular bin packing problem with free rotations. **European Journal of Operational Research**, v. 258, n. 2, p. 440–455, 2017. Citado na página 7.

PLANKOVSKYY, S.; TSEGELNYK, Y.; SHYPUL, O.; PANKRATOV, A.; ROMANOVA, T. Cutting irregular objects from the rectangular metal sheet. In: **Integrated Computer Technologies in Mechanical Engineering**. [S.l.]: Springer, 2020. p. 150–157. Citado na página 7.

RAKOTONIRAINY, R. G. A machine learning approach for automated strip packing algorithm selection. **ORiON**, v. 36, n. 2, p. 73–88, 2020. Citado na página 19.

SATO, A. K.; MARTINS, T. C.; GOMES, A. M.; TSUZUKI, M. S. G. Raster penetration map applied to the irregular packing problem. **European Journal of Operational Research**, Elsevier, v. 279, n. 2, p. 657–671, 2019. Citado na página 7.

SUTTON, R. S.; BARTO, A. G. **Reinforcement learning: An introduction**. [S.l.]: MIT press, 2018. Citado na página 19.

TOLEDO, F. M. B.; CARRAVILLA, M. A.; RIBEIRO, C.; OLIVEIRA, J. F.; GOMES, A. M. The dotted-board model: A new mip model for nesting irregular shapes. **International Journal of Production Economics**, Elsevier, v. 145, n. 2, p. 478–487, 2013. Citado 11 vezes nas páginas 5, 8, 10, 11, 12, 13, 14, 16, 17, 18 e 30.

WÄSCHER, G.; HAUBNER; SCHUMANN, H. H. e. An improved typology of cutting and packing problems. **European Journal of Operational Research**, v. 183, p. 1109–1130, 2007. Citado na página 7.

ŽUNIĆ, A. Shape diameter for object analysis. **Information Processing Letters**, Elsevier, v. 136, p. 76–79, 2018. Citado na página 12.

APÊNDICE A - ALGORITMOS

A seguir são apresentados os algoritmos para o método *Q-learning* utilizando a abordagem *1-eixos* (Algoritmo 3) e *Recipiente dividido* (Algoritmo 4).

Algoritmo 3: *Q-learning* para geração de malhas aleatórias - Método *1-eixo*

Parâmetros: P, $\lambda > 0$, $MaxIter$, n_i e os demais parâmetros do modelo;
Inicializar $Q \leftarrow 0$; ; Inicializar $prob \leftarrow 1$; % Probabilidade de explorar;
Inicializar $MelhorCusto \leftarrow 0$;
Inicializar $prob \leftarrow 1$; % Probabilidade de explorar;
while $k \leq MaxIter$ **do**
  $r \leftarrow rand(0,1)$;
  if $r \leq prob$ **then**
    São escolhidos aleatoriamente p_i^*, $\forall i$;
  else
    p_{ij}^* são escolhidos utilizando uma **Roleta ponderada parcial**;
  Gerar a malha M com os parâmetros escolhidos;
  $CustoAtual \leftarrow$ Custo do problema resolvido com M;
  if $CustoAtual \geq MelhorCusto$ **then**
    $MelhorCusto \leftarrow CustoAtual$;
    $Q_{ip_i^*} \leftarrow Q_{ip_i^*} + 1$, $\forall i$
  $k \leftarrow k + 1$;
  $prob \leftarrow e^{-\lambda * k}$
retorna Q

Algoritmo 4: *Q-learning* para geração de malhas aleatórias - Método *Recipiente dividido*

```
Seja j ∈ {1,2} o parâmetros responsável por indicar a partição do recipiente;
Parâmetros: P, λ > 0, MaxIter, n_i e os demais parâmetros do modelo;
Inicializar Q ← 0;  ; Inicializar prob ← 1;  % Probabilidade de explorar;
Inicializar MelhorCusto ← 0;
Inicializar prob ← 1;  % Probabilidade de explorar;
while k ≤ MaxIter do
    r ← rand(0,1);
    if r ≤ prob then
        São escolhidos aleatoriamente p*_ij, ∀i, j;
    else
        p*_ij são escolhidos utilizando uma Roleta ponderada parcial;
    Gerar a malha M com os parâmetros escolhidos;
    CustoAtual ← Custo do problema resolvido com M;
    if CustoAtual ≥ MelhorCusto then
        MelhorCusto ← CustoAtual;
        Q_ijp*_ij ← Q_ijp*_ij + 1, ∀i, j
    k ← k + 1;
    prob ← e^(−λ∗k)
retorna Q
```

APÊNDICE B - RESULTADOS COMPLEMENTARES

Neste apêndice, são detalhados e complementados os resultados apresentados no texto do TCC. Desta forma, ficam documentados todos os resultados obtidos ao longo deste trabalho.

B.1. Evolução do *Q-learning*

A evolução da qualidade da solução encontrada durante as iterações do método *Q-learning* para as instâncias $blazewicz_1$ e $marques_1$ são apresentadas nas Figuras 14 e 15, respectivamente. O eixo-x do gráfico destaca as iterações onde houve melhora no valor da melhor solução incumbente, enquanto que o eixo-y apresenta em quantas unidades a solução atual é melhor que a anterior. Vale relembrar que os resultados obtidos para a instância rco_1 foram reportados no Capítulo 5.

Figura 14 – Instância $blazewicz_1$ - Evolução do *Q-learning*

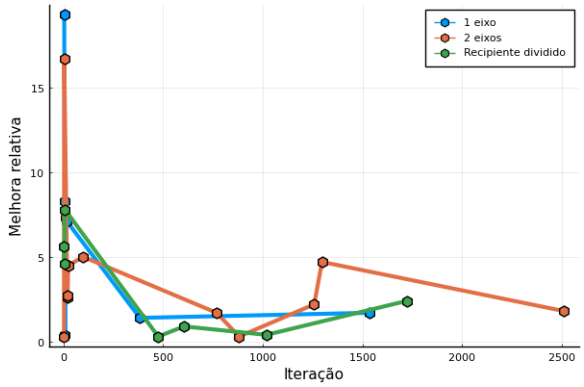

Figura 15 – Instância $marques_1$ - Evolução do *Q-learning*

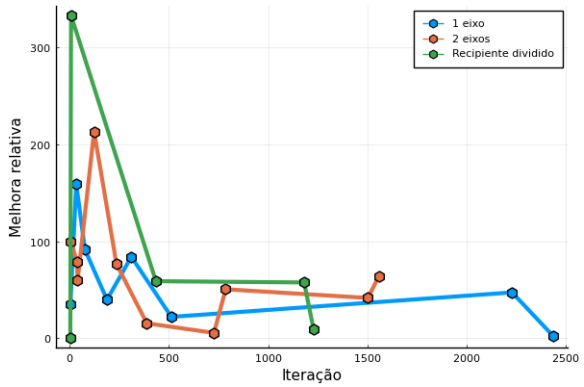

B.2. Resultados Computacionais

Nas Tabelas 6 a 17, são apresentados os resultados para as abordagens avaliadas: malhas regulares, malhas sem e com treinamento (abordagens 1-eixo, 2-eixos e recipiente divido), e considera as opções de malhas com 33%, 66% e 100% do total de pontos. Mais especificamente, as Tabelas 6, 10 e 14 contêm os resultados das malhas sem treinamento para as porcentagens 33%, 66% e 100% de pontos, respectivamente. Analogamente, as Tabelas 7, 11 e 15 mostram os resultados das malhas obtidas pelo método *1-eixo*, as Tabelas 8, 12 e 16 são referentes ao método *2-eixos*, enquanto as Tabelas 9, 13 e 17 correspondem aos resultados das malhas obtidas pelo método *Recipiente dividido*.

Como as malhas possuem aleatoriedade, foram utilizadas as médias e desvios padrão para comparações mais justas. Nas tabelas, a coluna ”Instância” identifica a instância resolvida, ”NV” é o número de variáveis do modelo, ”Área-M (%)” é a porcentagem média de ocupação do *bin*, ”Área-D (%)” seu desvio padrão da área, ”T (s)” é o tempo médio de resolução da instância em segundos (não foi considerado o tempo gasto para gerar a instância) e ”T-D”seu desvio padrão e ”GAP-M (%)” é o desvio relativo médio da melhor solução obtida para seu limitante dual e ”GAP-D”seu desvio padrão. O número de observações usado para calcular a média e desvio padrão foi 5 para todas as instâncias.

Tabela 6 – Resultados para malhas geradas Sem treinamento - 33%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	615	69,4	2,1	8	3	0,0	0,0
rco_2	611	65,4	1,3	14	3	0,0	0,0
rco_3	611	66,6	1,2	14	5	0,0	0,0
rco_4	611	66,0	1,5	25	17	0,0	0,0
rco_5	611	64,9	2,1	35	36	0,0	0,0
$blazewicz_1$	615	65,9	1,0	7	2	0,0	0,0
$blazewicz_2$	611	62,9	0,9	12	4	0,0	0,0
$blazewicz_3$	611	61,8	1,6	20	5	0,0	0,0
$blazewicz_4$	611	60,9	0,4	106	49	0,0	0,0
$blazewicz_5$	611	62,9	2,1	37	31	0,0	0,0
$marques_1$	1209	73,6	1,3	185	217	0,0	0,0
$marques_2$	1206	69,2	1,1	735	610	0,0	0,0

Tabela 7 – Resultados para malhas geradas pelo método *1 eixo* - 33%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	615	69,6	1,5	4	1	0,0	0,0
rco_2	611	64,6	0,7	9	2	0,0	0,0
rco_3	611	65,8	1,9	16	9	0,0	0,0
rco_4	611	63,3	1,1	23	12	0,0	0,0
rco_5	611	64,1	2,7	21	15	0,0	0,0
$blazewicz_1$	615	58,7	0,8	11	5	0,0	0,0
$blazewicz_2$	611	55,3	0,8	10	3	0,0	0,0
$blazewicz_3$	611	54,9	1,5	15	3	0,0	0,0
$blazewicz_4$	611	54,4	2,6	232	279	0,0	0,0
$blazewicz_5$	611	54,8	1,4	15	3	0,0	0,0
$marques_1$	1209	74,9	0,3	55	8	0,0	0,0
$marques_2$	1206	69,5	2,4	110	122	0,0	0,0

Tabela 8 – Resultados para malhas geradas pelo método *2 eixos* - 33%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	615	71,0	1,1	4	<1	0,0	0,0
rco_2	611	66,3	0,6	7	<1	0,0	0,0
rco_3	611	67,7	1,7	8	3	0,0	0,0
rco_4	611	66,0	1,3	12	6	0,0	0,0
rco_5	611	66,2	0,5	9	4	0,0	0,0
$blazewicz_1$	615	68,2	1,0	2	<1	0,0	0,0
$blazewicz_2$	611	62,4	1,9	5	1	0,0	0,0
$blazewicz_3$	611	63,7	1,6	4	2	0,0	0,0
$blazewicz_4$	611	61,7	0,4	20	11	0,0	0,0
$blazewicz_5$	611	63,9	0,8	7	6	0,0	0,0
$marques_1$	1209	73,2	0,9	28	12	0,0	0,0
$marques_2$	1206	70,7	1,4	32	11	0,0	0,0

As Tabelas 18 e 19 mostram a comparação feita entre a malha aleatória treinada por *2-eixos* e a malha sem treinamento para as porcentagens 33% e 100%. Valores negativos (em vermelho) mostram melhor desempenho da malha sem treinamento, enquanto que valores positivos (em azul) indicam vantagem da abordagem *2-eixos*. Note que para a porcentagem de 100%, o desvio padrão das malhas *2-eixos* sempre é maior, porém isso ocorrer

A compração entre a abordagem *2-eixos* com 33% e 100% dos pontos e a malha regular é apresentada nas Tabelas 20 e 21, respectivamente. Valores negativos (em vermelho) mostram melhor desempenho da malha regular, enquanto que valores positivos (em azul) indicam vantagem da abordagem *2-eixos*.

Tabela 9 – Resultados para malhas geradas pelo método *Recipiente dividido* - 33%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	615	70,3	1,3	3	1	0,0	0,0
rco_2	611	67,5	1,4	6	<1	0,0	0,0
rco_3	611	66,6	1,1	8	2	0,0	0,0
rco_4	611	66,1	1,5	12	6	0,0	0,0
rco_5	611	65,5	1,8	9	3	0,0	0,0
$blazewicz_1$	615	66,2	1,4	6	1	0,0	0,0
$blazewicz_2$	611	62,2	0,6	22	19	0,0	0,0
$blazewicz_3$	611	62,9	1,8	9	2	0,0	0,0
$blazewicz_4$	611	61,0	0,1	102	66	0,0	0,0
$blazewicz_5$	611	62,6	0,9	13	4	0,0	0,0
$marques_1$	1209	73,0	0,4	78	56	0,0	0,0
$marques_2$	1206	68,9	2,5	265	305	0,0	0,0

Tabela 10 – Resultados para malhas geradas Sem treinamento - 66%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	1224	74,5	1,6	65	25	0,0	0,0
rco_2	1220	70,5	0,8	397	179	0,0	0,0
rco_3	1220	71,1	0,8	496	273	0,0	0,0
rco_4	1220	71,2	1,1	507,0	294	0,0	0,0
rco_5	1220	70,0	2,1	913	823	1,4	2,2
$blazewicz_1$	1224	70,2	0,9	464	389	0,0	0,0
$blazewicz_2$	1220	68,1	0,4	731	235	0,0	0,0
$blazewicz_3$	1220	67,9	1,0	1207	567	0,8	1,3
$blazewicz_4$	1220	66,6	3,1	1655	324	3,4	4,3
$blazewicz_5$	1220	67,4	0,8	1450	532	1,4	1,7
$marques_1$	2412	75,6	1,2	1800	<1	6,4	1,5
$marques_2$	2409	72,9	1,2	1800	<1	9,8	1,3

Tabela 11 – Resultados para malhas geradas pelo método *1 eixo* - 66%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	1224	73,7	1,1	48	11	0,0	0,0
rco_2	1220	68,6	0,3	219	36	0,0	0,0
rco_3	1220	70,3	1,3	310	198	0,0	0,0
rco_4	1220	69,5	1,0	208	125	0,0	0,0
rco_5	1220	70,0	2,1	430	671	0,0	0,0
$blazewicz_1$	1224	63,9	0,3	77	16	0,0	0,0
$blazewicz_2$	1220	60,3	1,9	378	237	0,0	0,0
$blazewicz_3$	1220	60,3	1,8	518	124	0,0	0,0
$blazewicz_4$	1220	60,5	0,2	1656	321	3,0	2,1
$blazewicz_5$	1220	58,5	1,3	641	249	0,0	0,0
$marques_1$	2412	78,2	0,9	1800	<1	4,0	1,0
$marques_2$	2409	73,3	1,2	1800	<1	6,6	2,8

Tabela 12 – Resultados para malhas geradas pelo método *2 eixos* – 66%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	1224	75,5	1,1	36	14	0,0	0,0
rco_2	1220	70,6	1,3	41	9	0,0	0,0
rco_3	1220	72,1	1,4	117	140	0,0	0,0
rco_4	1220	71,6	0,8	62	30	0,0	0,0
rco_5	1220	71,0	0,5	43	9	0,0	0,0
$blazewicz_1$	1224	71,0	0,9	30	7	0,0	0,0
$blazewicz_2$	1220	67,8	0,5	135	27	0,0	0,0
$blazewicz_3$	1220	68,3	1,1	151	75	0,0	0,0
$blazewicz_4$	1220	68,3	0,5	178	81	0,0	0,0
$blazewicz_5$	1220	68,7	0,9	123	25	0,0	0,0
$marques_1$	2412	78,1	0,7	723	601	0,0	0,0
$marques_2$	2409	74,7	1,1	1800	<1	2,8	1,5

Tabela 13 – Resultados para malhas geradas pelo método *Recipiente dividido* – 66%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	1224	77,2	1,2	40	15	0,0	0,0
rco_2	1220	71,7	1,0	46	21	0,0	0,0
rco_3	1220	70,8	1,0	261	196	0,0	0,0
rco_4	1220	71,1	0,9	82	79	0,0	0,0
rco_5	1220	70,8	1,3	198	159	0,0	0,0
$blazewicz_1$	1224	71,2	0,4	93	34	0,0	0,0
$blazewicz_2$	1220	68,7	0,9	363	183	0,0	0,0
$blazewicz_3$	1220	67,6	0,9	362	84	0,0	0,0
$blazewicz_4$	1220	67,9	0,5	1657	319	1,6	1,3
$blazewicz_5$	1220	68,3	0,8	416	244	0,0	0,0
$marques_1$	2412	76,8	0,9	1800	<1	2,8	1,3
$marques_2$	2409	73,7	0,4	1579	493	4,2	2,5

Tabela 14 – Resultados para malhas geradas Sem treinamento – 100%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	1850	77,0	1,0	612	665	0,4	0,9
rco_2	1846	73,8	0,7	1800	<1	2,6	0,9
rco_3	1846	74,2	1,2	1758	92	3,2	2,2
rco_4	1846	72,0	0,9	1800	<1	5,2	1,9
rco_5	1846	72,8	0,5	1800	<1	4,6	0,9
$blazewicz_1$	1850	72,7	0,6	1800	<1	4,0	0,7
$blazewicz_2$	1846	71,0	1,0	1800	<1	4,4	1,8
$blazewicz_3$	1846	69,4	1,0	1800	<1	5,8	1,1
$blazewicz_4$	1846	68,3	0,4	1800	<1	9,0	1,2
$blazewicz_5$	1846	70,4	1,0	1800	<1	6,0	1,0
$marques_1$	3650	77,7	0,8	1800	<1	13,4	1,1
$marques_2$	3647	73,7	1,2	1800	<1	17,6	1,5

Tabela 15 – Resultados para malhas geradas pelo método *1 eixo* – 100%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	1850	77,1	0,6	121	37	0,0	0,0
rco_2	1846	72,4	0,8	935	506	0,0	0,0
rco_3	1846	73,8	0,8	1405	391	0,6	0,9
rco_4	1846	71,1	0,5	1800	<1	3,6	0,9
rco_5	1846	72,4	0,5	1576	326	1,6	2,1
$blazewicz_1$	1850	67,1	1,0	1344	685	1,0	1,7
$blazewicz_2$	1846	63,7	1,2	1503	344	0,4	0,5
$blazewicz_3$	1846	63,0	0,8	1800	<1	3,4	1,5
$blazewicz_4$	1846	60,6	0,4	1800	<1	10,4	1,9
$blazewicz_5$	1846	62,2	1,4	1741	132	2,8	2,2
$marques_1$	3650	79,3	0,9	1801	2	9,8	1,5
$marques_2$	3647	73,0	1,4	1801	2	15,8	1,5

Tabela 16 – Resultados para malhas geradas pelo método *2 eixos* – 100%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	1850	77,1	0,8	118	26	0,0	0,0
rco_2	1846	73,2	1,2	545	601	0,0	0,0
rco_3	1846	74,3	1,4	1167	760	0,8	1,1
rco_4	1846	73,4	0,8	1145	613	0,2	0,4
rco_5	1846	71,7	0,4	1430	516	0,6	0,9
$blazewicz_1$	1850	74,1	0,4	204	141	0,0	0,0
$blazewicz_2$	1846	69,3	1,1	1157	594	0,8	1,1
$blazewicz_3$	1846	70,8	0,6	910	540	0,2	0,4
$blazewicz_4$	1846	69,3	0,3	1800	<1	3,0	1,2
$blazewicz_5$	1846	70,6	1,0	1265	497	0,6	0,9
$marques_1$	3650	79,4	0,8	1801	<1	7,0	1,4
$marques_2$	3647	76,3	0,3	1801	2	9,6	0,9

Tabela 17 – Resultados para malhas geradas pelo método *Recipiente dividido* – 100%.

Instância	NV	Área-M (%)	Área-D (%)	T-M (s)	T-D (s)	GAP-M (%)	GAP-D (%)
rco_1	1850	78,9	0,4	138	36	0,0	0,0
rco_2	1846	73,3	1,3	908	532	0,0	0,0
rco_3	1846	73,4	0,8	1625	392	0,8	0,4
rco_4	1846	71,5	0,6	1800	<1	2,6	1,5
rco_5	1846	72,0	0,1	1593	304	1,0	1,0
$blazewicz_1$	1850	72,9	1,2	1621	401	2,2	1,5
$blazewicz_2$	1846	70,1	0,5	1706	210	2,4	1,7
$blazewicz_3$	1846	69,0	0,8	1800	<1	5,4	1,3
$blazewicz_4$	1846	68,3	0,2	1800	<1	8,8	1,1
$blazewicz_5$	1846	70,5	1,0	1800	<1	4,0	1,6
$marques_1$	3650	77,9	0,2	1800	<1	10,4	0,5
$marques_2$	3647	73,2	0,9	1800	<1	15,0	1,6

Tabela 18 – Comparação dos resultados malha *2-eixos* x malha *Sem treinamento* - 33%.

Instância	D-Área (%)	SD-Área (%)	D-T (s)	SD-T (s)
rco_1	1.6	1.0	4	2
rco_2	0.9	0.7	7	3
rco_3	1.1	-0.5	6	2
rco_4	0.0	0.2	12	11
rco_5	1.3	1.6	27	32
$blazewicz_1$	2.3	-0.0	5	2
$blazewicz_2$	-0.5	-1.0	7	3
$blazewicz_3$	1.9	-0.0	16	3
$blazewicz_4$	0.8	-0.0	86	37
$blazewicz_5$	1.0	1.3	30	26
$marques_1$	-0.4	0.4	156	205
$marques_2$	1.5	-0.3	699	599

Tabela 19 – Comparação dos resultados malha *2-eixos* x malha *Sem treinamento* - 100%.

Instância	D-Área (%)	SD-Área (%)	D-T (s)	SD-T (s)
rco_1	0.1	0.2	494	639
rco_2	-0.6	-0.5	1255	-600
rco_3	0.1	-0.2	591	-668
rco_4	1.4	0.1	655	-613
rco_5	-1.1	0.1	371	-516
$blazewicz_1$	1.4	0.2	1597	-141
$blazewicz_2$	-1.7	-0.1	644	-594
$blazewicz_3$	1.4	0.4	891	-539
$blazewicz_4$	1.0	0.1	1	>-1
$blazewicz_5$	0.2	-0.0	536	-496
$marques_1$	1.7	-0.0	>-1	-1
$marques_2$	2.6	0.9	>-1	-2

Tabela 20 – Comparação dos resultados malha *2-eixos* x malha regular – 33%.

Instância	D-Área (%)	SD-Área (%)	D-T (s)	SD-T (s)
rco_1	-25,8	1,1	89	<1
rco_2	-24,7	0,6	580	<1
rco_3	-22,7	1,7	1792	3
rco_4	-24,0	1,3	1788	6
rco_5	-21,4	0,5	1792	4
$blazewicz_1$	-26,7	1,0	195	<1
$blazewicz_2$	-22,1	1,9	1795	<1
$blazewicz_3$	-19,7	1,6	1796	2
$blazewicz_4$	-21,7	0,4	1780	11,4
$blazewicz_5$	-20,6	0,8	1793	6
$marques_1$	-12,7	0,9	824	12
$marques_2$	-7,3	1,4	1768	11

Tabela 21 – Comparação dos resultados malha *2-eixos* x malha regular – 100%.

Instância	D-Área (%)	SD-Área (%)	D-T (s)	SD-T (s)
rco_1	-19,7	0,8	-26	26
rco_2	-17,8	1,2	42	601
rco_3	-16,1	1,4	633	760
rco_4	-16,6	0,8	654	613
rco_5	-15,9	0,4	371	516
$blazewicz_1$	-20,8	0,4	-7	141
$blazewicz_2$	-15,2	1,1	643	594
$blazewicz_3$	-12,6	0,6	890	540
$blazewicz_4$	-14,1	0,3	<1	<1
$blazewicz_5$	-13,9	1,0	536	497
$marques_1$	-6,5	0,8	-949	1
$marques_2$	-1,7	0,3	-1	2

APÊNDICE C - EXEMPLO DE SOLUÇÕES

A seguir encontram-se as representações gráficas das soluções encontradas para as instâncias mais relevantes. Itens em mesma cor representam as peças que compõe o mesmo produto final. Em cada figura é destacada a porcentagem de ocupação do objeto (”Per”), o tempo necessário para obter esta solução (”Tempo”) e o desvio para a solução ótima (”’GAP”), que quando igual a zero indica que a solução obtida é comprovadamente ótima para a malha que está sendo considerada.

Soluções com malhas regulares

Figura 16 – Solução com malha regular - Instância rco_1.

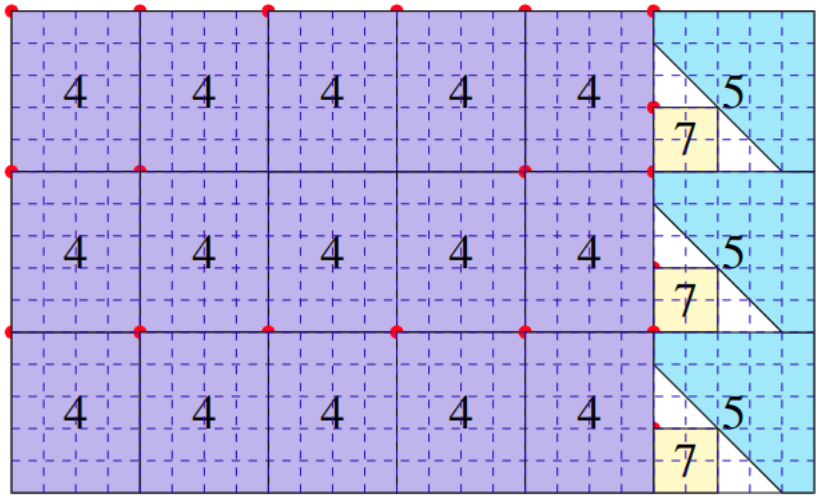

Per = 96.8%
Tempo = 87.18
GAP = 0.0%

Figura 17 – Solução com malha regular - Instância rco_2.

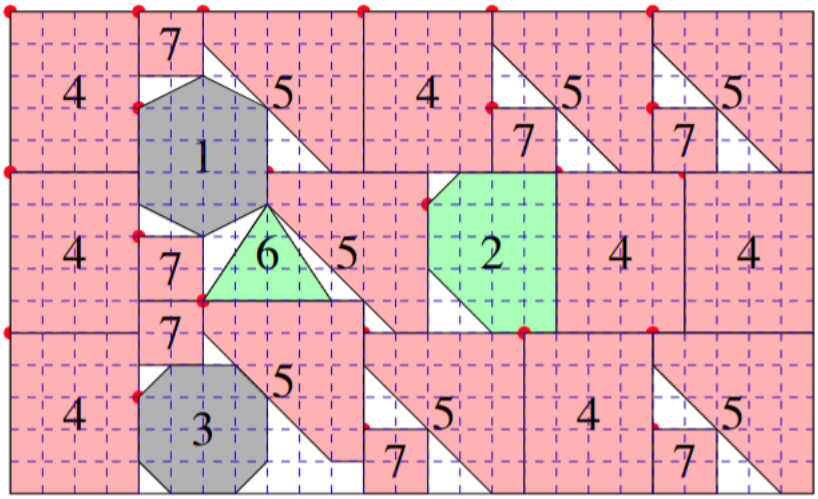

Per = 91.0%
Tempo = 551.18
GAP = 0.0%

Figura 18 – Solução com malha regular - Instância rco_3.

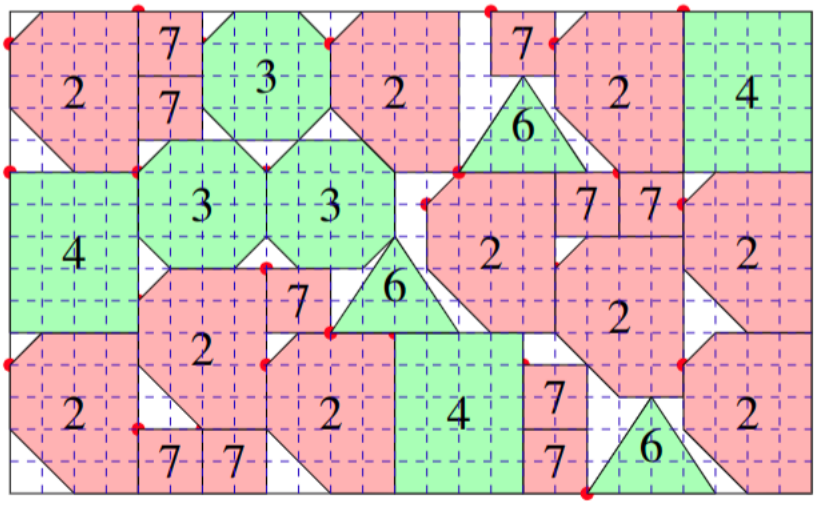

Per = 90.0%
Tempo = 1800.02
GAP = 2.3%

Figura 19 – Solução com malha regular - Instância rco_4.

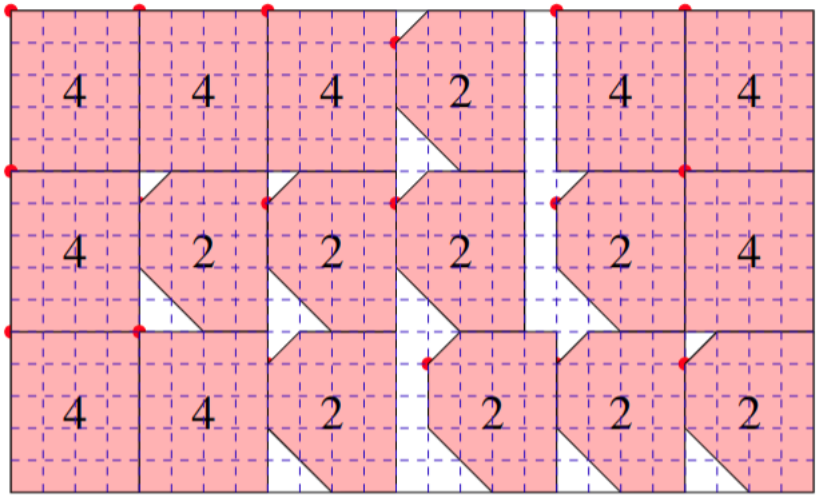

Per = 90.0%
Tempo = 1800.15
GAP = 0.4%

Figura 20 – Solução com malha regular - Instância rco_5.

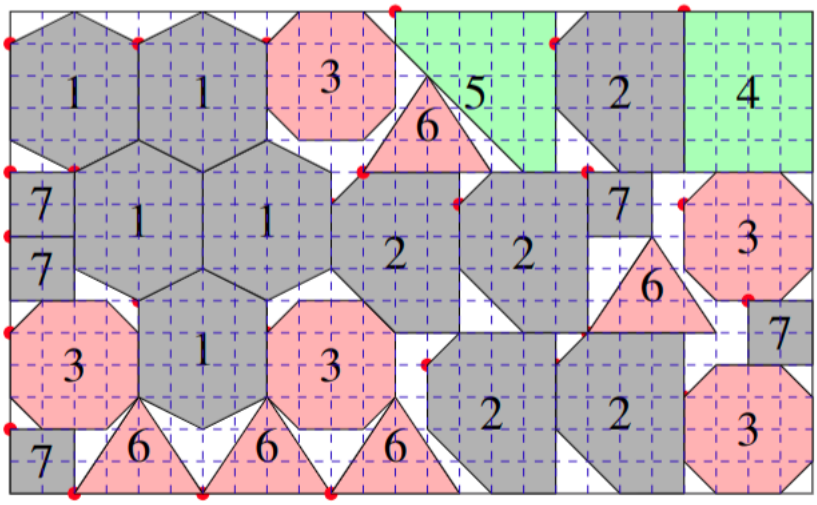

Per = 87.6%
Tempo = 1800.02
GAP = 3.7%

Figura 21 – Solução com malha regular - Instância $blazewicz_1$.

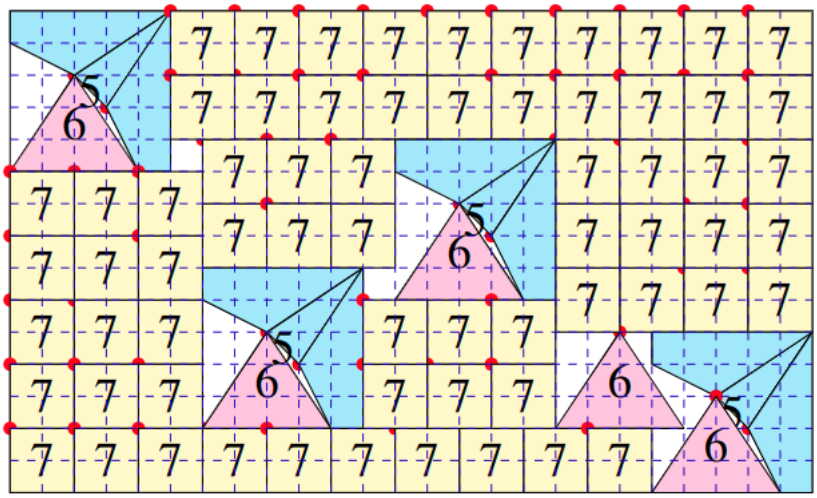

Per = 94.9%
Tempo = 181.2
GAP = 0.0%

Figura 22 – Solução com malha regular - Instância $blazewicz_2$.

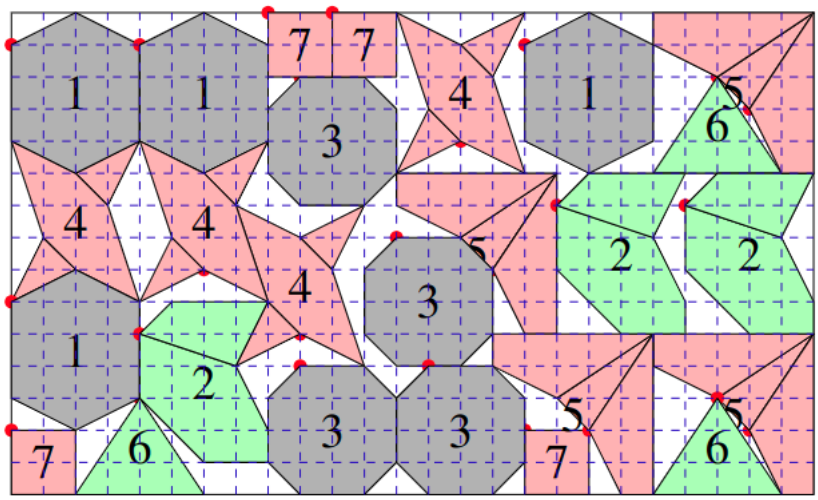

Per = 84.5%
Tempo = 1800.03
GAP = 4.2%

Figura 23 – Solução com malha regular - Instância *blazewicz*$_3$.

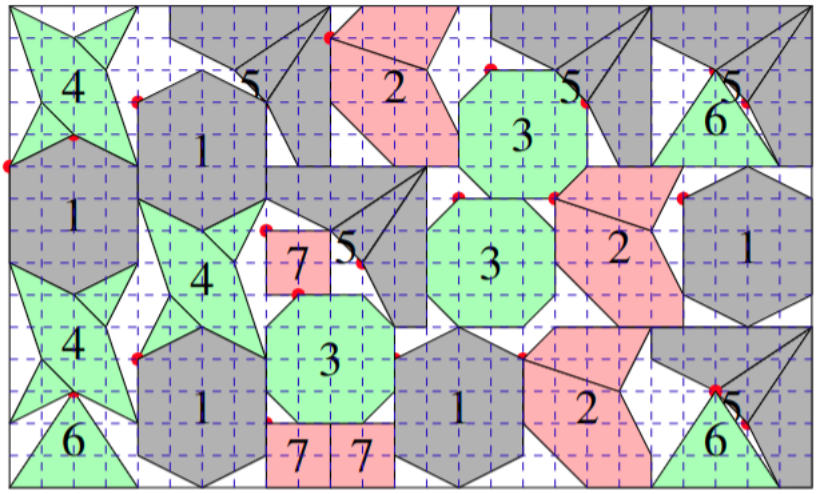

Per = 84.1%
Tempo = 1800.03
GAP = 5.1%

Figura 24 – Solução com malha regular - Instância *blazewicz*$_4$.

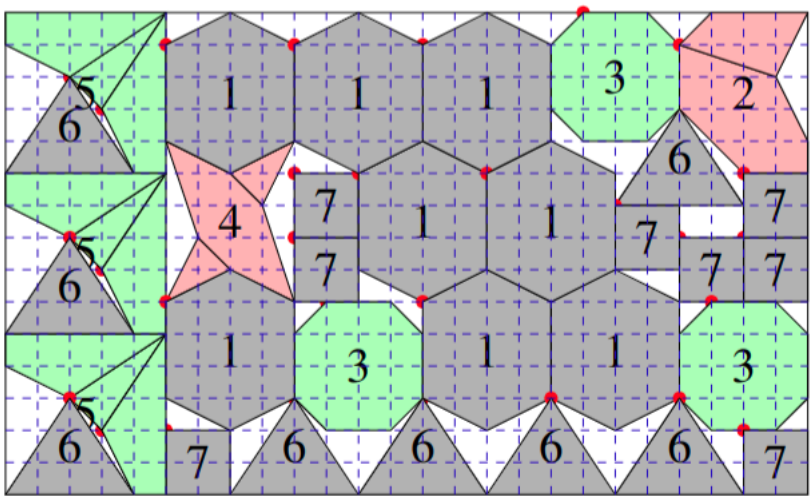

Per = 87.8%
Tempo = 1800.04
GAP = 3.1%

Figura 25 – Solução com malha regular - Instância $blazewicz_5$.

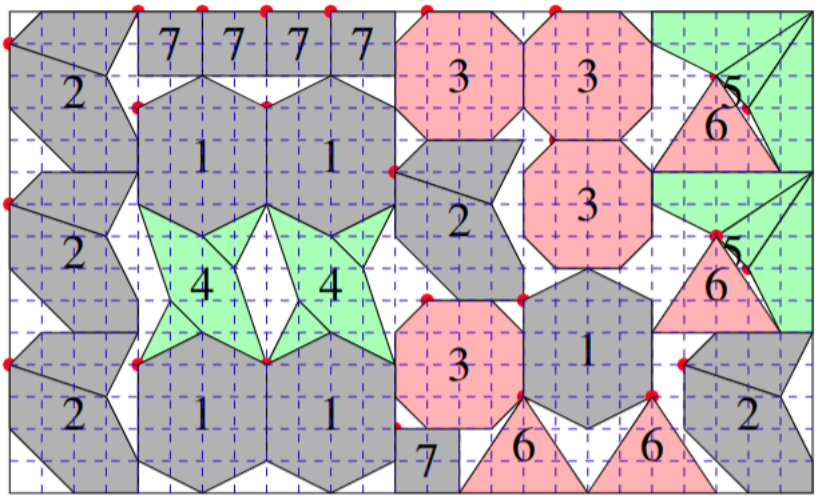

Per = 84.7%
Tempo = 1800.03
GAP = 5.3%

Figura 26 – Solução com malha regular - Instância $marques_1$.

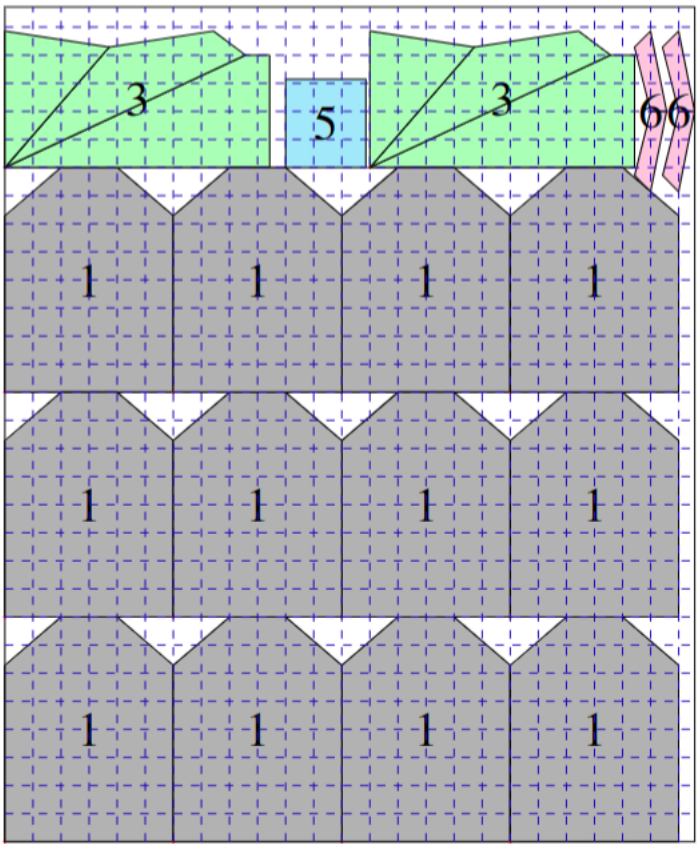

Per = 85.9%
Tempo = 1079.34
GAP = 0.0%

Figura 27 – Solução com malha regular - Instância $marques_2$.

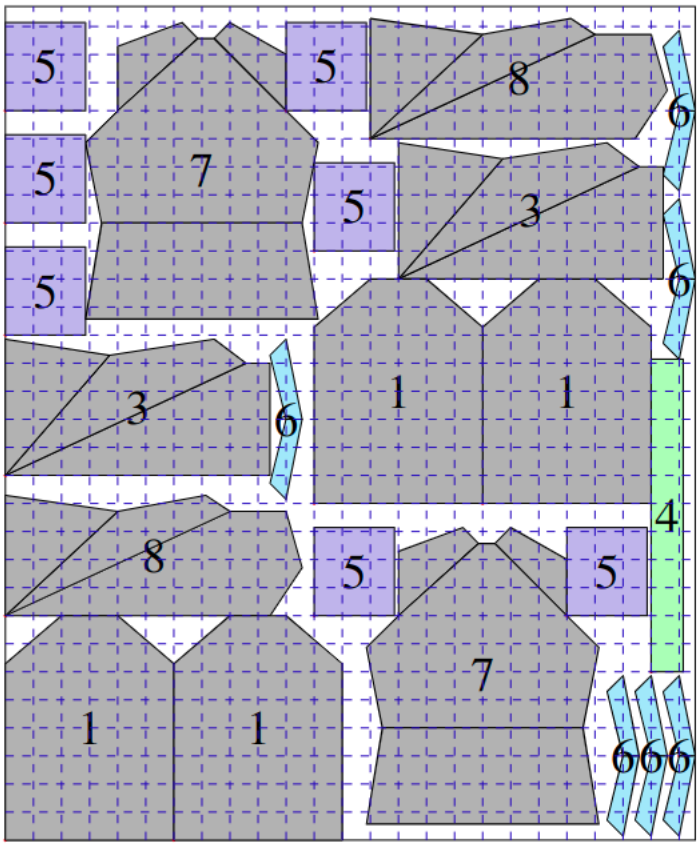

Per = 77.3%
Tempo = 1800.26
GAP = 8.6%

Soluções com malha aleatória

Figura 28 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância rco_1.

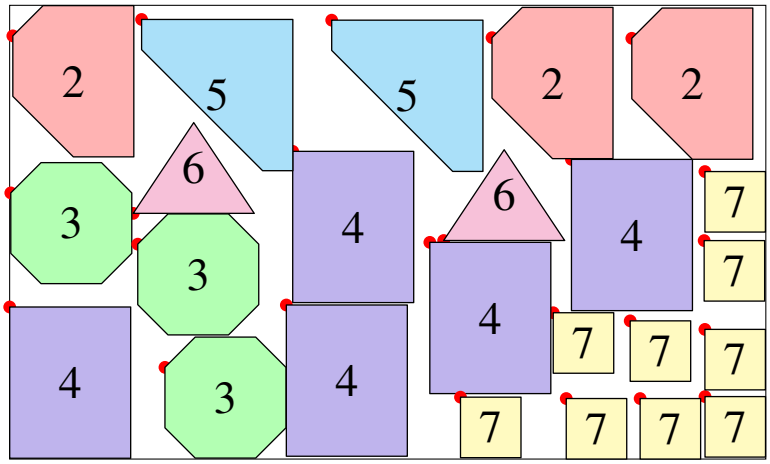

Per = 74.2%
Tempo = 21.01
GAP = 0.0%

Figura 29 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância rco_2.

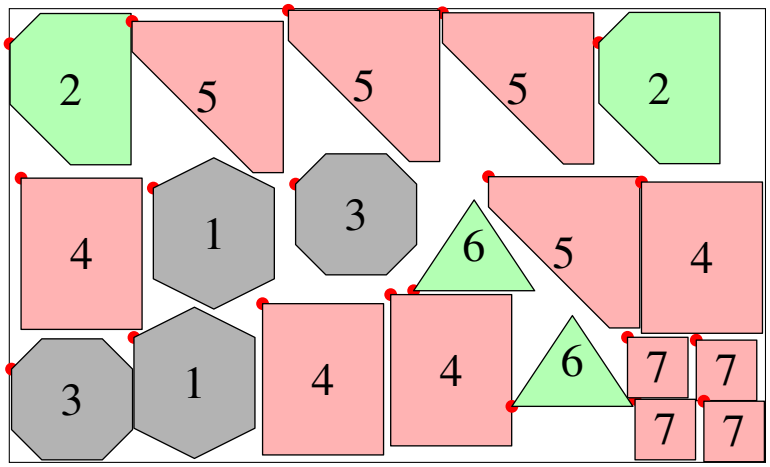

Per = 72.7%
Tempo = 30.63
GAP = 0.0%

Figura 30 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância rco_3.

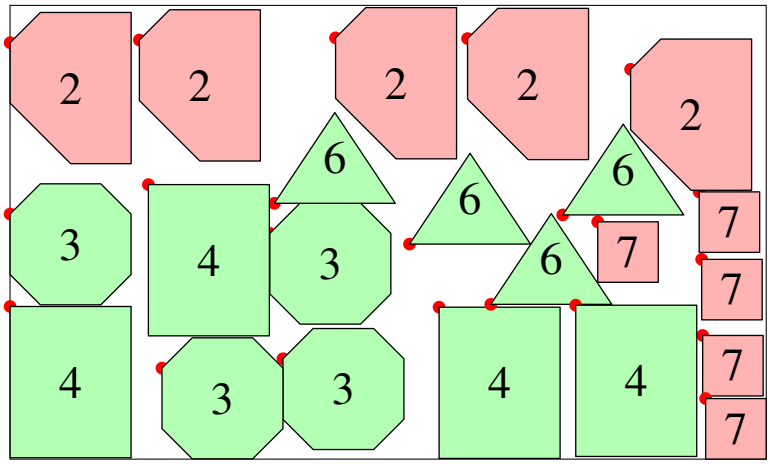

Per = 72.2%
Tempo = 111.52
GAP = 0.0%

Figura 31 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância rco_4.

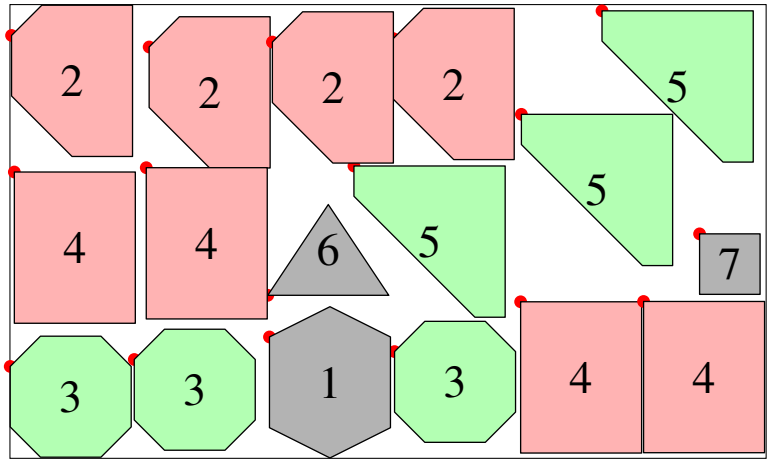

Per = 71.9%
Tempo = 105.8
GAP = 0.0%

Figura 32 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância rco_5.

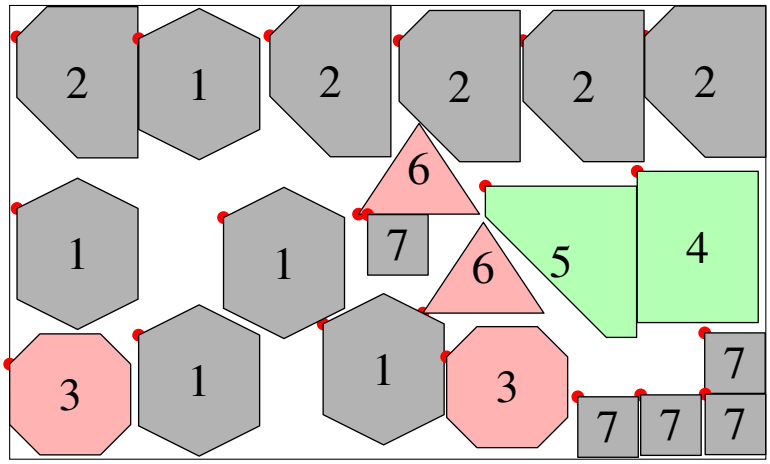

Per = 71.0%
Tempo = 42.03
GAP = 0.0%

Figura 33 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância $blazewicz_1$

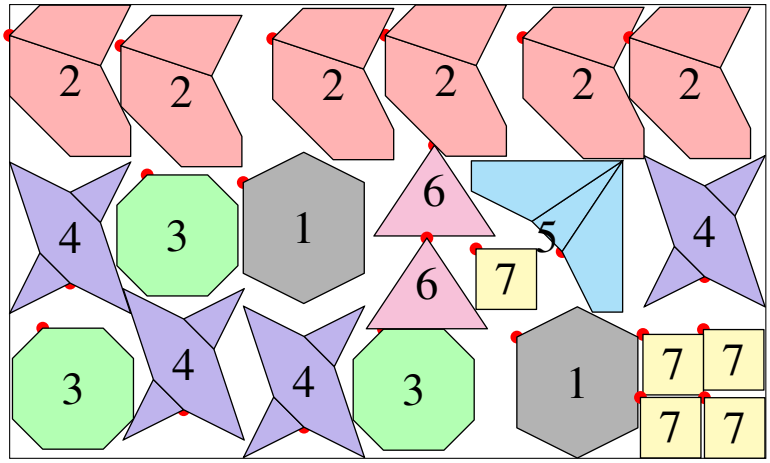

Per = 72.3%
Tempo = 18.43
GAP = 0.0%

Figura 34 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância $blazewicz_2$

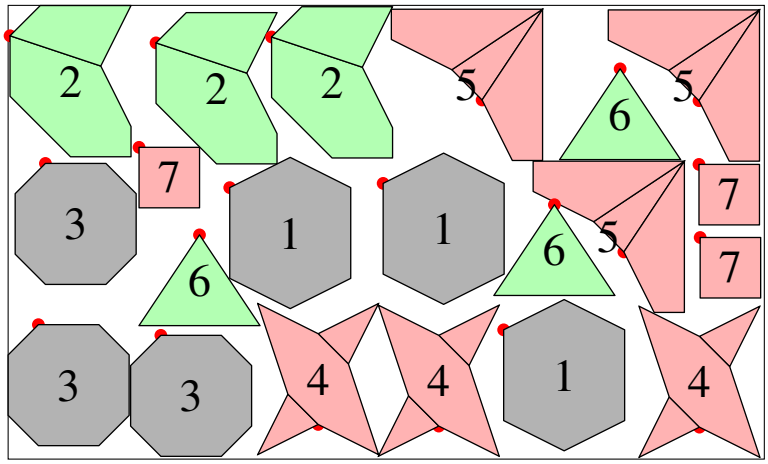

Per = 67.8%
Tempo = 132.91
GAP = 0.0%

Figura 35 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância $blazewicz_3$

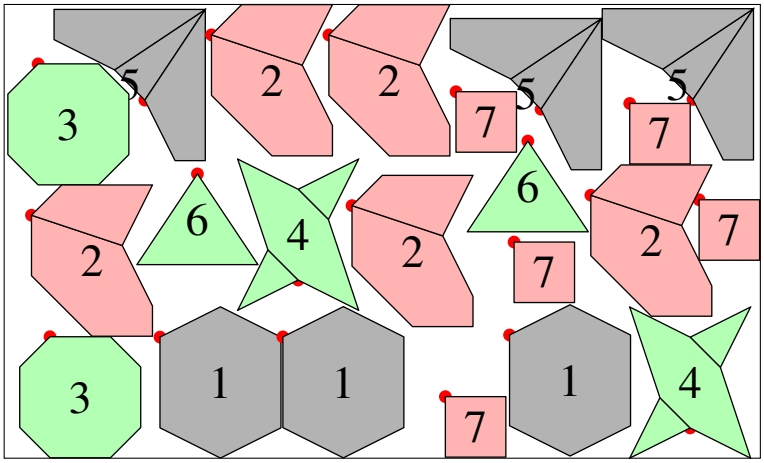

Per = 69.0%
Tempo = 174.38
GAP = 0.0%

Figura 36 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância $blazewicz_4$

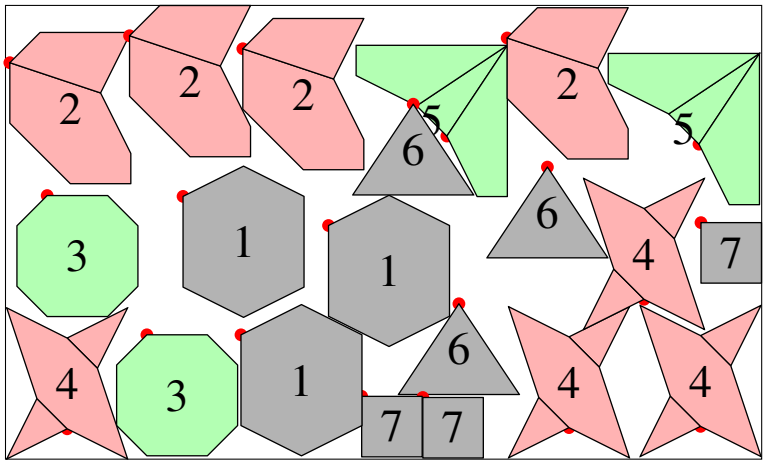

Per = 68.1%
Tempo = 133.68
GAP = 0.0%

Figura 37 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância $blazewicz_5$

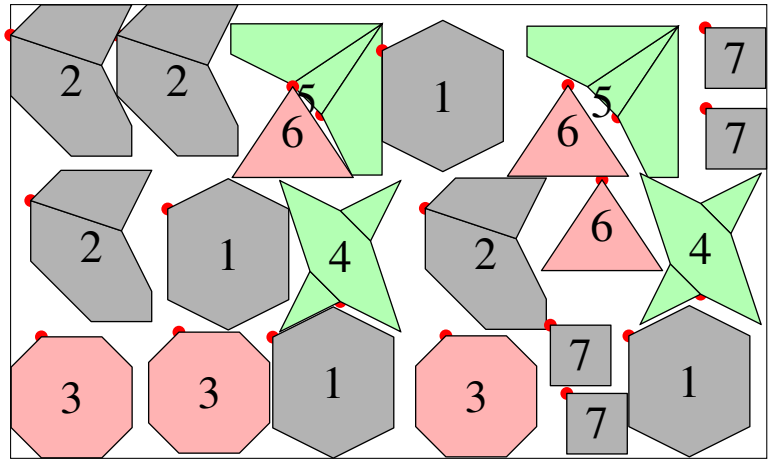

Per = 69.7%
Tempo = 112.86
GAP = 0.0%

Figura 38 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância $marques_1$

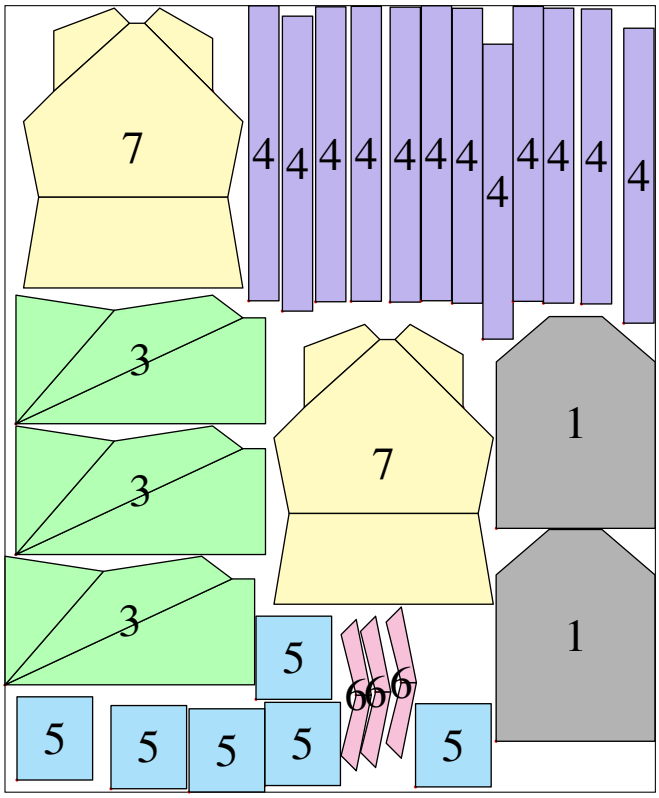

Per = 78.3%
Tempo = 200.55
GAP = 0.0%

Figura 39 – Solução com malha aleatória - Método *2-eixos* - p = 66% - Instância $marques_2$

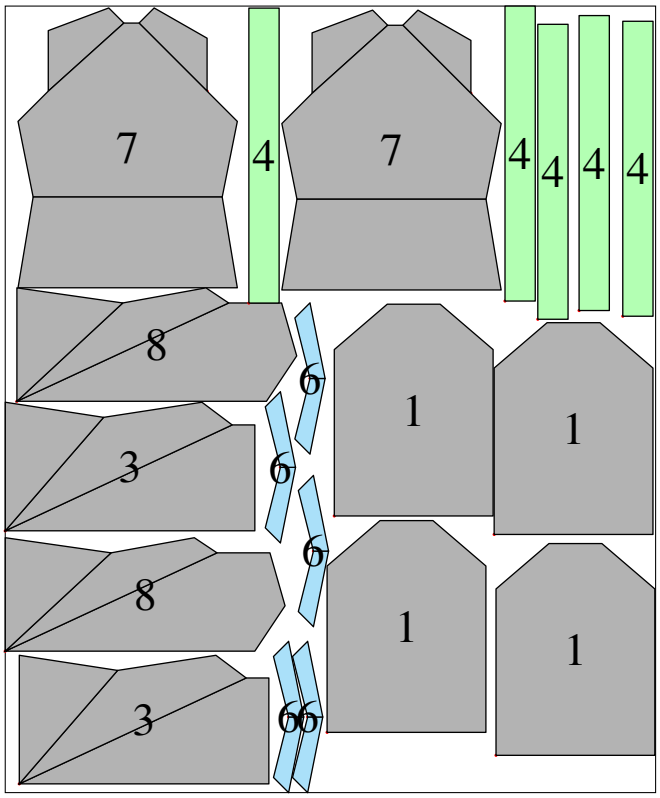

Per = 75.4%
Tempo = 1800.09
GAP = 4.4%